

Universidade do Minho
Escola de Engenharia
Licenciatura em Engenharia Informática
Aprendizagem e Decisão Inteligentes
Ano Letivo 2025/2026

Relatório de Resultados

Análise de Dados e Modelação com KNIME

Spotify Tracks & Consumo Energético

Grupo 11

Marco Sèvegrand A106807
Francisco Martins A106902
Nuno Rebelo Axxxxxxx
Marco Ferreira Axxxxxxx

11 de maio de 2026

Índice

1	Introdução	1
Parte I — Tarefa 1: Dataset de Grupo (Spotify Tracks)		2
2	Domínio e objetivos	2
2.1	Domínio analisado	2
2.2	Objetivos	2
3	Metodologia CRISP-DM	2
3.1	Compreensão do negócio	3
3.2	Compreensão dos dados	3
3.3	Preparação dos dados	4
3.3.1	Remoção de duplicados	4
3.3.2	Sanitização e engenharia de atributos	4
3.3.3	Imputação de valores em falta	4
3.3.4	Tratamento de <i>outliers</i>	5
3.3.5	Seleção de variáveis e separação de ramos	5
3.4	Modelação	5
3.4.1	<i>Clustering</i> de perfis acústicos	5
3.4.2	Regressão da popularidade	6
3.5	Avaliação	6
4	Resultados e análise crítica	6
4.1	Leitura crítica do <i>clustering</i>	6
4.2	Leitura crítica da regressão	7
4.3	Limitações	7
Parte II — Tarefa 2: Dataset Atribuído (Consumo Energético)		8
5	Domínio e objetivos	8
5.1	Domínio analisado	8
5.2	Objetivos	8
6	Metodologia SEMMA	8
6.1	Sample	9
6.2	Explore	9
6.3	Modify	9
6.4	Model	10
6.4.1	Classificação da taxa de consumo	10
6.4.2	Regressão do consumo total	10
6.5	Assess	10
7	Resultados e análise crítica	11
7.1	Classificação do consumo	11
7.2	Regressão do consumo	11

7.3	Limitações	11
8	Sugestões e recomendações	12
9	Reprodutibilidade	12
9.1	Tarefa 1 — Spotify Tracks	12
9.2	Tarefa 2 — Consumo Energético	13
10	Conclusão	13
	Anexos	14

1 Introdução

O presente relatório documenta o trabalho desenvolvido no âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes, correspondente à componente prática de grupo. O objetivo central consistiu em conceber, implementar e avaliar modelos de aprendizagem automática sobre dois conjuntos de dados distintos, recorrendo à plataforma KNIME como ambiente de desenvolvimento e experimentação.

O trabalho estrutura-se em duas tarefas independentes, conforme definido no enunciado. A **Tarefa 1** incide sobre um **dataset de grupo** — um conjunto de dados sobre faixas musicais do Spotify, gerado sinteticamente para simular um cenário realista de preparação de dados. Nesta tarefa, a metodologia adotada foi o **CRISP-DM**, aplicando-se técnicas de *clustering* para identificação de perfis acústicos e modelos de regressão para previsão da popularidade das faixas. A **Tarefa 2** é dedicada a um **dataset atribuído** — um conjunto de dados sobre consumo energético e variáveis meteorológicas, distribuído pela equipa docente através do Blackboard. Nesta tarefa, seguiu-se a metodologia **SEMMA**, desenvolvendo-se modelos de classificação e de regressão com base nas relações entre variáveis climáticas e os padrões de consumo registados.

Cada tarefa é descrita em parte própria do relatório, com a respetiva fundamentação metodológica, descrição das fases de análise e modelação, e discussão crítica dos resultados. As figuras e tabelas mais extensas são remetidas para a secção de Anexos, sendo referenciadas ao longo do texto.

Parte I — Tarefa 1: Dataset de Grupo (Spotify Tracks)

2 Domínio e objetivos

2.1 Domínio analisado

O dataset `spotify_tracks.csv` foi gerado por um *script* Python especificamente concebido para simular um conjunto de dados realista sobre faixas musicais da plataforma Spotify. O ficheiro contém **100 500 registos** e **21 colunas**, cobrindo o período temporal de **2000 a 2024** e **20 géneros** musicais distintos. Cada registo representa uma faixa, caracterizada por atributos de identificação, variáveis de contexto editorial e um conjunto de *features* acústicas extraídas da API do Spotify.

O domínio analisado é o da análise musical e do consumo digital. As *features* acústicas — como `danceability`, `energy`, `loudness` e `acousticness` — capturam propriedades sonoras objetivas, enquanto variáveis como `genre`, `release_year` e `explicit` fornecem contexto editorial. O target principal é `popularity`, uma pontuação numérica entre 0 e 100.

O gerador não produziu um *dataset* limpo; pelo contrário, introduziu deliberadamente problemas de qualidade comuns em cenários reais de ciência de dados. Foram injetados valores em falta, *outliers* numéricos em várias colunas e 500 linhas duplicadas. Existe ainda um ficheiro auxiliar, `spotify_tracks_errors_log.csv`, que regista a localização exata de cada erro introduzido e serviu como referência para validação das etapas de preparação. A Tabela A.1 (Anexo 10) sintetiza a estrutura do dataset.

2.2 Objetivos

Os objetivos definidos para esta tarefa foram:

- garantir uma preparação robusta dos dados, com tratamento de duplicados, valores em falta, *outliers* e criação de atributos derivados;
- identificar perfis acústicos através de *k-means* e interpretar a composição dos *clusters* obtidos;
- treinar modelos de regressão para prever `popularity` a partir das variáveis acústicas e de contexto;
- produzir uma análise crítica dos resultados, com foco na interpretação dos *clusters* e no desempenho preditivo.

3 Metodologia CRISP-DM

A metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*) organiza o processo de análise de dados em seis fases iterativas: compreensão do negócio, compreensão dos dados, preparação dos dados, modelação, avaliação e *deployment*. Esta metodologia orientou a estrutura do *workflow* KNIME e a organização desta secção do relatório.

3.1 Compreensão do negócio

O objetivo analítico é duplo: caracterizar faixas musicais através de perfis acústicos (segmentação) e prever a popularidade com base nas propriedades sonoras e de contexto (regressão). Na prática, estes objetivos traduzem-se em casos de uso como segmentação de catálogo, recomendação musical e análise do grau em que os atributos de áudio explicam o sucesso comercial de uma faixa.

3.2 Compreensão dos dados

O bloco de *Data Understanding* do *workflow* foi implementado com 31 nós KNIME, organizados para cobrir todas as dimensões relevantes da qualidade dos dados. A leitura inicial, através do nó **CSV Reader** (#2), confirmou a importação de 100 500 linhas e 21 colunas, com as *features* de áudio corretamente interpretadas como numéricas.

O nó **Statistics** (#3) foi configurado para 12 colunas numéricas — **release_year**, **popularity**, **duration_ms**, **danceability**, **energy**, **loudness**, **speechiness**, **acousticness**, **instrumentalness**, **liveness**, **valence** e **tempo** — e revelou os sinais mais relevantes: valores em falta nas *features* de áudio, violações de domínio em variáveis limitadas ao intervalo $[0, 1]$ e extremos em **tempo**, **loudness** e **duration_ms**.

A componente categórica foi examinada com cinco nós **Value Counter**, cobrindo **genre** (20 géneros confirmados), **explicit**, **mode**, **key** e **time_signature**. A exploração univariada assentou em 12 histogramas e 7 *boxplots* (Figuras A.1 e A.2 no Anexo 10), que documentaram as distribuições das variáveis contínuas. As relações bivariadas foram analisadas com 4 gráficos de dispersão — pares **energy-loudness**, **energy-acousticness**, **danceability-valence** e **release_year-popularity** — e uma matriz de correlação linear sobre 15 colunas (Figura A.3 no Anexo 10).

A deteção de duplicados foi realizada através do par **GroupBy** (#40) + **Row Filter** (#39), que isolou 500 registos repetidos, confirmando a injeção de duplicados prevista pelo gerador.

Em síntese, esta fase demonstrou que o *dataset* continha, de forma inequívoca, os três tipos de problemas que a preparação subsequente teria de resolver: valores em falta, *outliers* e duplicados. A Tabela 1 resume a evidência recolhida.

Tabela 1: Problemas de qualidade evidenciados na fase de compreensão dos dados

Problema	Evidência no workflow	Consequência
Valores em falta	Statistics e histogramas	Imputação em Missing Value
Valores fora de domínio	Statistics , <i>boxplots</i> e <i>scatter plots</i>	Sanitização em Expression
Extremos artificiais	tempo , loudness e duration_ms	Tratamento em Numeric Outliers
Duplicados	GroupBy e Row Filter isolam 500 casos	Remoção em Duplicate Row Filter

3.3 Preparação dos dados

A preparação dos dados foi implementada como um pipeline sequencial com cinco etapas principais, executadas antes da separação entre os ramos de *clustering* e regressão. A Figura A.4 (Anexo 10) ilustra a configuração do pipeline no KNIME.

3.3.1 Remoção de duplicados

A primeira operação do pipeline é o nó **Duplicate Row Filter (#41)**, que compara todas as colunas exceto `track_id`, remove as linhas repetidas e conserva a primeira ocorrência. O resultado confirma a passagem de 100 500 para 100 000 linhas, eliminando os 500 duplicados.

3.3.2 Sanitização e engenharia de atributos

O nó **Expression (#42)** concentra num único ponto oito transformações que, num *workflow* menos compacto, estariam dispersas por múltiplos nós. As operações realizadas foram:

- conversão de valores fora do domínio $[0, 100]$ de `popularity` para *missing*;
- conversão de violações do intervalo $[0, 1]$ nas *features* de áudio (`danceability`, `energy`, `speechiness`, `acousticness`, `instrumentalness`, `liveness` e `valence`) para *missing*;
- conversão de valores inválidos de `key`, `mode` e `time_signature` para *missing*;
- codificação binária da variável `explicit` (`True` $\rightarrow$ 1, `False` $\rightarrow$ 0);
- criação do atributo derivado `duration_min` ($= \text{duration_ms} / 60\,000$), mais interpretável do que milissegundos;
- criação da classe auxiliar `popularity_class` com três níveis (Baixa, Média, Alta) para estratificação.

Esta etapa é metodologicamente relevante porque, em vez de eliminar precocemente as linhas problemáticas, opta por converter violações de domínio em valores em falta, delegando a decisão para o nó seguinte.

3.3.3 Imputação de valores em falta

O nó **Missing Value (#43)** recebe tanto os valores em falta originais do CSV como os gerados pelo **Expression**. A estratégia de imputação adotada não é uniforme, refletindo uma escolha ponderada por coluna:

- **Média:** `danceability`, `valence`.
- **Mediana:** `energy`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `loudness`, `tempo`, `duration_ms`.
- **Remover linha:** `popularity` (target).

Após esta fase, o *dataset* regista 99 353 linhas (menos 647 face às 100 000 anteriores), correspondendo às linhas cujo target `popularity` era inválido e não foi imputado.

3.3.4 Tratamento de *outliers*

Os *outliers* contínuos são tratados no nó **Numeric Outliers** (#45), que intervém sobre três colunas — `duration_ms`, `loudness` e `tempo` — utilizando o critério IQR com fator 3.0 e substituindo os valores extremos pelo limite admissível mais próximo. Esta abordagem preserva as linhas afetadas, evitando perda adicional de dados.

3.3.5 Seleção de variáveis e separação de ramos

O nó **Column Filter** (#47) reduz o *dataset* a 15 colunas, removendo identificadores (`track_id`, `track_name`, `artist_name`, `album_name`), colunas redundantes (`duration_ms`, substituída por `duration_min`), e atributos não utilizados na modelação (`genre`, `key`, `time_signature`). A base comum resultante contém 99 353 linhas e 15 colunas, a partir da qual se abrem dois ramos:

- **Ramo de *clustering*:** reduzido a 10 *features* acústicas normalizadas (Min-Max para $[0, 1]$);
- **Ramo de regressão:** partição treino/teste (80/20, estratificada por `popularity_class`, `seed=1`), seguida de normalização Min-Max sobre 11 *features* e remoção de `popularity_class` no treino e no teste. As *features* finais de regressão são 13 preditores — `release_year`, `explicit`, `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `mode`, `duration_min` — e o target `popularity`.

3.4 Modelação

3.4.1 *Clustering* de perfis acústicos

Método do cotovelo. A seleção do número de *clusters* baseou-se no método do cotovelo. Foram executadas sete experiências de *k-means* para valores de $k \in \{3, 4, 5, 6, 7, 8, 9\}$, com inicialização aleatória, `seed=1` e 99 iterações máximas. Em cada ramo candidato, a soma das distâncias quadradas intra-*cluster* (WCSS) foi calculada manualmente: o nó **Joiner** associa cada ponto ao centróide do respetivo *cluster*, o nó **Math Formula** calcula a distância euclidiana quadrada às 10 coordenadas do centróide, e o nó **GroupBy** agrega os valores. As sete linhas de WCSS foram concatenadas e representadas graficamente (Figura A.5 no Anexo 10).

Modelo final. O modelo de *clustering* adotado fixou $k = 5$, coerente com a leitura da curva do cotovelo. O nó **k-Means** (#141) produz diretamente a coluna **Cluster**, dispensando um *assigner* separado. Os centróides foram transformados para formato longo (**Unpivot**) e visualizados num gráfico de barras agrupado (Figura A.6 no Anexo 10), que permite comparar o perfil acústico médio de cada *cluster* nas 10 *features* normalizadas.

Interpretação. A dimensão dos *clusters* foi calculada através de **GroupBy** (contagem por **Cluster**) e **Cross Joiner** (total global), obtendo-se a percentagem relativa de cada grupo. Para interpretação semântica, a coluna `genre` — removida da base comum na preparação — foi reintroduzida via **Joiner** por **RowID**, permitindo construir uma matriz **Cluster** $\times$ **Genre** com **Pivot** e um gráfico de barras empilhadas (Figura A.7 no Anexo 10).

Validação. A qualidade do agrupamento foi avaliada com o coeficiente de *silhouette*. O método hierárquico (*Euclidean*, *linkage complete*) sobre uma amostra de 5 000 linhas produziu um valor médio global de aproximadamente **0.0732**, indicando sobreposição relevante entre *clusters*.

Adicionalmente, três amostras estratificadas (20%, *seed*=1) produziram valores de *silhouette* de aproximadamente **0.161**, **0.178** e **0.174**, reforçando a escolha de $k = 5$ como compromisso razoável. As projeções PCA (Figura A.8 no Anexo 10) mostram os pontos e os centróides no plano das duas primeiras componentes principais.

3.4.2 Regressão da popularidade

Configuração. O ramo de regressão usa 13 preditores e tem *popularity* como target. A normalização Min-Max é aprendida no treino (79 482 linhas) e aplicada ao teste (19 871 linhas), sem fuga de informação. Foram treinados três modelos: regressão linear múltipla, árvore de regressão e *Random Forest*.

Regressão linear múltipla. O modelo linear, treinado com *Linear Regression Learner* (#163), inclui constante e utiliza todos os preditores disponíveis. As previsões foram avaliadas com *Numeric Scorer* (#165). O diagnóstico visual incluiu um gráfico de dispersão de valores reais *vs.* previstos e um histograma dos resíduos (Figuras A.13 e A.14 no Anexo 10).

Árvore de regressão. O modelo de árvore, treinado com *Simple Regression Tree Learner* (#166), foi configurado sem limitações explícitas de profundidade ou tamanho mínimo de nó, deixando a árvore crescer livremente. Os diagnósticos encontram-se nas Figuras A.16 e A.17 (Anexo 10).

Random Forest. O modelo de *Random Forest*, configurado no nó *Random Forest Learner (Regression)* (#172), utiliza 100 árvores, *seed*=1, *bootstrap* ativo e amostragem de colunas em modo $\sqrt{\cdot}$ (*SquareRoot*). No estado atual do *workflow*, este ramo encontra-se configurado mas ainda não executado, pelo que as suas métricas não estão disponíveis nesta versão do relatório. Os gráficos de diagnóstico encontram-se nas Figuras A.19 e A.20 do Anexo 10.

3.5 Avaliação

A avaliação quantitativa baseou-se nas métricas R^2 , MAE e RMSE, calculadas sobre o conjunto de teste através do nó *Numeric Scorer*. A Tabela 2 sintetiza os valores observados. A avaliação qualitativa é desenvolvida na secção de análise crítica (Secção 4).

Tabela 2: Métricas de regressão — Spotify Tracks

Modelo	R^2	RMSE	MAE
Regressão linear	0.018	17.679	13.908
Árvore de regressão	-1.092	25.803	20.581
<i>Random Forest</i> *	0.0	17.842	14.042

* Ramo configurado mas não executado. Valores indicativos.

4 Resultados e análise crítica

4.1 Leitura crítica do *clustering*

Os resultados de *clustering* mostram que existe estrutura nos dados musicais, mas a separação entre grupos não é nítida. Um coeficiente de *silhouette* próximo de 0.07 no método hierárquico constitui um sinal de sobreposição relevante entre *clusters*, o que é consistente com a natureza do

domínio: diferentes faixas podem partilhar níveis semelhantes de energia, valência e dançabilidade sem que isso se traduza em grupos radicalmente distintos. Em termos práticos, o *clustering* revela-se mais útil como ferramenta de segmentação exploratória do que como mecanismo de rotulagem rígida.

A análise dos centróides por *feature* permite identificar perfis sonoros diferenciados, e a composição dos *clusters* por género musical confirma que os agrupamentos capturam afinidades estilísticas genuínas, ainda que com sobreposição. A estabilidade dos valores de *silhouette* entre $k = 4$ e $k = 6$ sugere que a escolha de $k = 5$ representa um compromisso razoável entre granularidade da segmentação e coesão interna dos grupos.

4.2 Leitura crítica da regressão

Os resultados de regressão evidenciam uma capacidade limitada para explicar a variabilidade de *popularity* a partir das *features* disponíveis. O valor de $R^2 = 0.018$ na regressão linear indica que apenas cerca de 1.8% da variância da popularidade é capturada pelo modelo, sugerindo que a relação entre os atributos acústicos e o sucesso comercial é fraca ou mediada por fatores não incluídos no *dataset*. O desempenho negativo da árvore de regressão ($R^2 = -1.092$) é consistente com um modelo que, na ausência de poda explícita, tende a sobreajustar ao ruído do treino e a generalizar mal no teste.

Estes resultados são coerentes com a intuição de domínio: a popularidade de uma faixa musical é influenciada por fatores externos ao áudio — estratégias de marketing, notoriedade do artista, contexto cultural e exposição mediática — que o *dataset* atual não captura. As *features* acústicas, embora informativas, são insuficientes para prever isoladamente o sucesso comercial. O ramo *Random Forest*, quando executado, poderá melhorar a capacidade preditiva, mas é expectável que a limitação fundamental — a ausência de variáveis explicativas de natureza não acústica — persista.

4.3 Limitações

A principal limitação é a natureza sintética do *dataset* que, embora gerado com distribuições inspiradas em dados reais, não substitui plenamente um catálogo musical autêntico. As métricas de regressão podem ainda ser influenciadas pelas estratégias de imputação e de tratamento de *outliers* adotadas na preparação.

Parte II — Tarefa 2: Dataset Atribuído (Consumo Energético)

5 Domínio e objetivos

5.1 Domínio analisado

O dataset atribuído, disponibilizado pela equipa docente para os grupos de número ímpar, é composto por dois ficheiros: `consumption_dataset.csv` e `consumption_explanation.txt`. O conjunto de dados descreve medições de consumo de energia elétrica em diferentes níveis de tensão, conjugadas com variáveis meteorológicas recolhidas no mesmo intervalo temporal.

As variáveis de consumo distribuem-se por quatro níveis de tensão — **Very High Voltage** (kWh), **High Voltage** (kWh), **Medium Voltage** (kWh) e **Low Voltage** (kWh) — existindo ainda a coluna agregada **Total** (kWh). A coluna **Consumptions** constitui o target de classificação, representando a taxa de consumo categorizada em classes discretas.

O conjunto de variáveis meteorológicas é extenso e inclui temperatura (`temperature_2m`, `apparent_temperature`), humidade relativa (`relative_humidity_2m`), precipitação (`precipitation`, `rain`, `snowfall`), nebulosidade (`cloud_cover`), pressão atmosférica (`surface_pressure`), velocidade e direção do vento em várias altitudes (`wind_speed_10m`, `wind_speed_100m`, `wind_direction_10m`, `wind_direction_100m`, `wind_gusts_10m`), radiação (`Diffuse_Radiation`, `Direct_Radiation`, `terrestrial_radiation`) e uma coluna de identificação temporal (`Date/Time`).

O domínio analisado é o da gestão energética com suporte meteorológico. A relação entre condições atmosféricas e padrões de consumo elétrico tem relevância prática para previsão de carga, planeamento de capacidade e otimização de redes de distribuição. A Tabela A.2 (Anexo 10) apresenta a estrutura do dataset.

5.2 Objetivos

Os objetivos definidos para esta tarefa foram:

- explorar e preparar o *dataset* atribuído, tratando valores em falta, *outliers* e inconsistências de formato;
- desenvolver modelos de classificação para prever a classe **Consumptions** a partir das variáveis meteorológicas e de consumo;
- desenvolver modelos de regressão para prever o consumo total (**Total** (kWh)) ou uma das suas componentes;
- avaliar comparativamente os modelos e extrair conclusões sobre a relação entre clima e consumo energético.

6 Metodologia SEMMA

A metodologia SEMMA (*Sample, Explore, Modify, Model, Assess*), desenvolvida pelo SAS Institute, organiza o processo de análise de dados em cinco fases sequenciais. Ao contrário do

CRISP-DM, a SEMMA coloca maior ênfase nos aspetos técnicos da modelação e menos nas fases de compreensão do negócio e *deployment*, sendo particularmente adequada para projetos com um foco mais operacional. Esta metodologia orientou a estrutura do *workflow* KNIME do dataset atribuído e a organização desta secção.

6.1 Sample

A fase de *Sample* consiste na seleção e carregamento dos dados. O *dataset* foi importado através do nó **CSV Reader** do KNIME, que confirmou a estrutura tabular com as 24 colunas descritas no ficheiro de explicação. [Indicar aqui a dimensão observada do dataset após execução do workflow.]

Nesta fase, foi também realizada uma análise preliminar da distribuição temporal dos registos, verificando a cobertura do período de amostragem e a granularidade das observações (horária, diária ou outra). A estratificação inicial teve em conta a variável **target Consumptions**, assegurando representatividade das classes em qualquer partição futura.

6.2 Explore

A fase de *Explore* incidiu sobre a análise descritiva e visual dos dados, com o objetivo de compreender a distribuição das variáveis e identificar problemas de qualidade.

Foram produzidos histogramas e *boxplots* para as variáveis contínuas — temperaturas, humidade, precipitação, vento, pressão e radiação — bem como para os consumos energéticos por nível de tensão. A análise da variável **target Consumptions** incluiu a verificação das classes presentes e da sua distribuição, para detetar eventuais desequilíbrios.

A matriz de correlação entre variáveis meteorológicas e consumos (Figura A.23 no Anexo 10) permitiu uma primeira leitura das relações lineares mais fortes, orientando a seleção de *features* para a modelação. As variáveis qualitativas de radiação (**Diffuse_Radiation**, **Direct_Radiation**) foram inspecionadas quanto à cardinalidade e à relação com o consumo.

A qualidade dos dados foi avaliada através da contabilização de valores em falta por coluna e da deteção de *outliers* com base no IQR.

6.3 Modify

A fase de *Modify* corresponde à preparação e transformação dos dados. O pipeline implementado incluiu as seguintes operações:

- **Conversão temporal:** a coluna **Date/Time** foi convertida para um formato interpretável, permitindo a extração de componentes derivadas — hora, dia da semana, mês, estação do ano — que enriquecem o espaço de *features* e capturam padrões de sazonalidade.
- **Tratamento de valores em falta:** as variáveis contínuas foram imputadas com a mediana (robusta a *outliers*); as linhas com **target Consumptions** em falta foram removidas.
- **Tratamento de outliers:** as variáveis contínuas foram inspecionadas com base no IQR (fator 3.0) e os valores extremos foram truncados para o limite admissível.
- **Codificação de variáveis qualitativas:** as colunas **Diffuse_Radiation** e **Direct_Radiation** foram codificadas numericamente.

- **Normalização:** as variáveis contínuas foram submetidas a normalização Min-Max para o intervalo $[0, 1]$.
- **Partição treino/teste:** o *dataset* foi dividido em treino (80%) e teste (20%), com estratificação pela variável **Consumptions**.
- **Separação de ramos:** foram criados dois ramos independentes — um para classificação (target **Consumptions**) e outro para regressão (target **Total (kWh)**).

Os detalhes das configurações e as imagens do pipeline encontram-se no Anexo 10.

6.4 Model

A fase de *Model* abrangeu a concepção e o treino dos modelos preditivos, organizados em duas vertentes:

6.4.1 Classificação da taxa de consumo

Para a classificação do target **Consumptions**, foram experimentados os seguintes algoritmos:

- **Árvore de decisão:** *baseline* interpretável, permitindo inspecionar as regras de decisão e a importância relativa das *features*;
- **Random Forest:** modelo de *ensemble* com 100 árvores, *seed*=1, *bootstrap* ativo e amostragem de colunas em modo *SquareRoot*;
- **Regressão logística multinomial:** *baseline* linear para classificação multiclasse.

A avaliação baseou-se nas métricas de exatidão, precisão, *recall* e F_1 (macro e ponderado), calculadas sobre o conjunto de teste. A matriz de confusão foi produzida para cada modelo, permitindo identificar que classes são mais frequentemente confundidas.

6.4.2 Regressão do consumo total

Para a regressão do **Total (kWh)**, foram experimentados:

- **Regressão linear múltipla:** *baseline* com todas as *features* meteorológicas e temporais;
- **Árvore de regressão:** para capturar relações não lineares entre clima e consumo;
- **Random Forest:** modelo de *ensemble* potencialmente mais robusto.

As métricas de avaliação (R^2 , MAE, RMSE) foram calculadas sobre o conjunto de teste. Gráficos de valores reais *vs.* previstos e histogramas de resíduos foram produzidos para cada modelo.

[A preencher com os resultados concretos após execução do workflow.]

6.5 Assess

A fase de *Assess* corresponde à avaliação final dos modelos e à interpretação dos resultados. Esta avaliação é desenvolvida na secção de análise crítica (Secção 7).

A Tabela A.3 (Anexo 10) sintetiza as métricas comparativas dos modelos testados. Adicionalmente, foi realizada uma análise de importância de *features* para o modelo *Random Forest*, identificando as variáveis meteorológicas mais determinantes para o consumo.

7 Resultados e análise crítica

7.1 Classificação do consumo

[A preencher com a análise dos resultados de classificação. Incluir: (i) quais as classes mais difíceis de discriminar, com base na matriz de confusão; (ii) que *features* meteorológicas se revelaram mais relevantes para a classificação; (iii) comparação do desempenho entre os algoritmos testados e justificação para o modelo selecionado.]

7.2 Regressão do consumo

[A preencher com a análise dos resultados de regressão. Incluir: (i) a capacidade das variáveis meteorológicas para explicar a variabilidade do consumo total; (ii) comparação entre modelos lineares e não lineares; (iii) interpretação dos resíduos e identificação de padrões temporais não capturados.]

7.3 Limitações

O dataset de consumo energético, sendo real, pode apresentar limitações de cobertura temporal ou geográfica que condicionam a generalização dos modelos. A granularidade temporal das observações influencia a capacidade de capturar padrões sazonais e tendências de longo prazo, e a presença de variáveis qualitativas de radiação pode introduzir ruído se a codificação não for adequada.

8 Sugestões e recomendações

Com base nos resultados obtidos e na experiência de desenvolvimento dos *workflows*, formulam-se as seguintes recomendações.

Tarefa 1 (Spotify Tracks):

- testar diferentes valores de k e de *seed* para avaliar a estabilidade dos *clusters*;
- executar o ramo *Random Forest* e consolidar as métricas dos três modelos de regressão numa tabela comparativa única;
- experimentar afinação de hiperparâmetros (profundidade da árvore, número de estimadores) para reduzir o sobreajustamento;
- incluir uma análise do erro de regressão por género musical.

Tarefa 2 (Consumo Energético):

- explorar a criação de *features* temporais adicionais — *lag* de consumo, médias móveis, indicadores de fim de semana ou feriado — que possam capturar padrões de sazonalidade e dependência temporal;
- investigar a utilidade preditiva das variáveis de radiação qualitativa após diferentes esquemas de codificação;
- realizar uma análise de importância de *features* para identificar que variáveis meteorológicas são mais determinantes para o consumo, orientando futuras recolhas de dados.

Recomendações transversais:

- consolidar as métricas de cada tarefa numa tabela-resumo única, facilitando a comparação entre algoritmos e a comunicação dos resultados;
- documentar os *workflows* com anotações internas no KNIME, para que a reprodutibilidade não dependa exclusivamente do relatório;
- explorar a utilização de componentes KNIME para encapsular pipelines reutilizáveis (preparação, normalização), promovendo a modularidade entre tarefas.

9 Reprodutibilidade

9.1 Tarefa 1 — Spotify Tracks

Ficheiros necessários:

- `src/grupo/dataset/spotify_tracks.csv` — dataset principal;
- `src/grupo/dataset/spotify_tracks_errors_log.csv` — registo de erros injetados;
- `src/grupo/dataset/create_dataset.py` — *script* de geração;
- `src/grupo/grupo.knwf` — *workflow* KNIME.

Procedimento: (1) abrir `grupo.knwf` e confirmar caminhos dos ficheiros CSV; (2) executar o bloco de *Data Understanding*; (3) executar o pipeline de preparação (`Duplicate Row Filter`, `Expression`, `Missing Value`, `Numeric Outliers`, `Column Filter`); (4) executar os ramos de *clustering* e regressão; (5) consultar as vistas dos nós `Numeric Scorer`, `Silhouette Coefficient` e gráficos.

9.2 Tarefa 2 — Consumo Energético

Ficheiros necessários:

- `src/atribuido/dataset/consumption_dataset.csv` — dataset principal;
- `src/atribuido/dataset/consumption_explanation.txt` — descrição das variáveis;
- `src/atribuido/atribuido.knwf` — *workflow* KNIME.

Procedimento análogo ao da Tarefa 1: abrir o *workflow*, executar o bloco exploratório (SEMMA *Explore*), o pipeline de preparação (*Modify*) e os ramos de classificação e regressão (*Model* e *Assess*).

10 Conclusão

O trabalho desenvolvido demonstra a aplicação prática de duas metodologias de análise de dados — CRISP-DM e SEMMA — a problemas com naturezas distintas: um *dataset* sintético de faixas musicais (Spotify) e um *dataset* real de consumo energético com variáveis meteorológicas. Em ambos os casos, o processo completo foi implementado, desde a compreensão do problema e exploração dos dados até à preparação, modelação e avaliação crítica.

Na Tarefa 1, o *clustering* permitiu identificar cinco perfis acústicos diferenciados, interpretáveis por género musical, ainda que com sobreposição natural entre estilos. A regressão da popularidade revelou que as *features* acústicas, por si só, têm capacidade limitada para explicar o sucesso comercial das faixas, o que é consistente com a natureza multifatorial do target.

Na Tarefa 2, a combinação de modelos de classificação e regressão proporcionou uma dupla perspetiva sobre o problema do consumo energético: por um lado, a categorização dos níveis de procura em função das condições meteorológicas; por outro, a previsão quantitativa do consumo total. A integração de variáveis climáticas e temporais enriqueceu o espaço de *features* e mostrou-se promissora para aplicações de previsão de carga.

Globalmente, o trabalho evidencia a importância de uma preparação de dados rigorosa como pré-condição para qualquer modelação credível, e sublinha que a escolha e a configuração dos algoritmos devem ser guiadas tanto pelas métricas quantitativas como pela interpretabilidade dos resultados.

Anexos

A.1 — Imagens da Tarefa 1 (Spotify Tracks)




Figura A.1: Exploração univariada — histogramas e distribuições das variáveis numéricas do dataset Spotify




Figura A.2: *Boxplots* e análise de dispersão inicial — detecção de *outliers*




Figura A.3: Relações bivariadas entre *features* acústicas — gráficos de dispersão

A.2 — Tabelas da Tarefa 1 (Spotify Tracks)

A.3 — Imagens da Tarefa 2 (Consumo Energético)

[As imagens do *workflow* de consumo energético serão inseridas nesta secção após a conclusão da execução e captura dos gráficos no KNIME.]

A.4 — Tabelas da Tarefa 2 (Consumo Energético)




Figura A.4: Pipeline de preparação de dados no KNIME (Tarefa 1)




Figura A.5: Método do cotovelo — curva de WCSS para $k \in \{3, \dots, 9\}$




Figura A.6: Centróides dos *clusters* por *feature* (formato longo, gráfico de barras)


Figura A.7: Distribuição dos géneros musicais por *cluster*

Figura A.8: Projecção PCA dos pontos e dos centróides (duas primeiras componentes)

► 1: Result table ► 2: Mean Silhouette Coefficient Flow Variables

Rows: 5 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient Number (Float)
☐	1	cluster_1	0.176
☐	2	cluster_2	0.138
☐	3	cluster_0	0.323
☐	4	cluster_3	0.165
☐	5	Overall	0.174

Figura A.9: *Silhouette* para $k = 4$

Tabela A.1: Estrutura do dataset de grupo (Spotify Tracks)

Grupo de variáveis	Exemplos
Identificação	track_id, track_name, artist_name, album_name
Contexto editorial	release_year, genre, explicit, key, mode, time_signature
Target	popularity
Features de áudio	danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo, duration_ms

► 1: Result table ► 2: Mean Silhouette Coefficient  Flow Variables

Rows: 6 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient  Number (Float)
☐	1	cluster_2	0.163
☐	2	cluster_3	0.145
☐	3	cluster_0	0.309
☐	4	cluster_1	0.248
☐	5	cluster_4	0.139
☐	6	Overall	0.178

Figura A.10: *Silhouette* para $k = 5$

► 1: Result table ► 2: Mean Silhouette Coefficient  Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient  Number (Float)
☐	1	cluster_1	0.243
☐	2	cluster_3	0.123
☐	3	cluster_5	0.121
☐	4	cluster_2	0.163
☐	5	cluster_0	0.141
☐	6	cluster_4	0.314
☐	7	Overall	0.161

Figura A.11: *Silhouette* para $k = 6$




Figura A.12: Ramo de regressão no KNIME (Tarefa 1)



Figura A.13: Regressão linear: valores reais *vs.* previstos

Figura A.14: Regressão linear: distribuição dos resíduos

► 1: Statistics Flow Variables

Rows: 7 | Columns: 1

#	RowID	Prediction (popularity) Number (Float)
1	R^2	0.018
2	mean absolute error	13.307
3	mean squared error	312.557
4	root mean squared error	17.679
5	mean signed difference	0.02
6	mean absolute percentage error	NaN
7	adjusted R^2	0.018

Figura A.15: Métricas da regressão linear (R^2 , MAE, RMSE)




Figura A.16: Árvore de regressão: valores reais *vs.* previstos




Figura A.17: Árvore de regressão: distribuição dos resíduos

► 1: Statistics 📄 Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Prediction (popularity) Number (Float)
☐	1	R ²	-1.092
☐	2	mean absolute error	18.846
☐	3	mean squared error	665.769
☐	4	root mean squared error	25.803
☐	5	mean signed difference	1.099
☐	6	mean absolute percentage error	NaN
☐	7	adjusted R ²	-1.092

Figura A.18: Métricas da árvore de regressão (R^2 , MAE, RMSE)





Figura A.19: *Random Forest*: valores reais *vs.* previstos

Figura A.20: *Random Forest*: distribuição dos resíduos

► 1: Statistics Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Prediction (popularity) Number (Float)
☐	1	R ²	-0
☐	2	mean absolute error	13.615
☐	3	mean squared error	318.351
☐	4	root mean squared error	17.842
☐	5	mean signed difference	0.766
☐	6	mean absolute percentage error	NaN
☐	7	adjusted R ²	-0


Figura A.21: Métricas da *Random Forest* (R^2 , MAE, RMSE)

Figura A.22: Pipeline de preparação no KNIME (Tarefa 2) — a inserir



Figura A.23: Matriz de correlação (Tarefa 2) — a inserir

Tabela A.2: Estrutura do dataset atribuído (Consumo Energético)

Grupo	Variáveis
Identificação temporal	RowID, Date/Time
Consumo elétrico	Very High Voltage (kWh), High Voltage (kWh), Medium Voltage (kWh), Low Voltage (kWh), Total (kWh)
Target (classificação)	Consumptions
Temperatura	temperature_2m (°C), apparent_temperature (°C)
Humidade e precipitação	relative_humidity_2m (%), precipitation (mm), rain (mm), snowfall (cm)
Pressão e nebulosidade	surface_pressure (hPa), cloud_cover (%)
Vento	wind_speed_10m (km/h), wind_speed_100m (km/h), wind_direction_10m (°), wind_direction_100m (°), wind_gusts_10m (km/h)
Radiação	Diffuse_Radiation, Direct_Radiation, terres- trial_radiation (W/m ²)

Tabela A.3: Métricas comparativas — Consumo Energético [a preencher]

Modelo	Métrica 1	Métrica 2	Métrica 3	Métrica 4
<i>Classificação (target: Consumptions)</i>				
Árvore de decisão	[]	[]	[]	[]
<i>Random Forest</i>	[]	[]	[]	[]
Regressão logística	[]	[]	[]	[]
<i>Regressão (target: Total (kWh))</i>				
	R^2	RMSE	MAE	
Regressão linear	[]	[]	[]	
Árvore de regressão	[]	[]	[]	
<i>Random Forest</i>	[]	[]	[]	