

Universidade do Minho
Escola de Engenharia
Licenciatura em Engenharia Informática
Aprendizagem e Decisão Inteligentes
Ano Letivo 2025/2026

Relatório de Resultados

Análise de Dados e Modelação com KNIME

Spotify Tracks & Consumo Energético

Grupo 11

Marco Sèvegrand A106807
Francisco Martins A106902
Nuno Rebelo Axxxxxxx
Marco Ferreira Axxxxxxx

11 de maio de 2026

Índice

1	Introdução	1
Parte I — Tarefa 1: Dataset de Grupo (Spotify Tracks)		2
2	Domínio e objetivos	2
2.1	Domínio analisado	2
2.2	Objetivos	2
3	Metodologia CRISP-DM	3
3.1	Compreensão do negócio	3
3.2	Compreensão dos dados	3
3.3	Preparação dos dados	3
3.3.1	Remoção de duplicados	4
3.3.2	Sanitização e engenharia de atributos	4
3.3.3	Imputação de valores em falta	4
3.3.4	Tratamento de <i>outliers</i>	5
3.3.5	Seleção de variáveis e separação de ramos	5
3.4	Modelação	5
3.4.1	<i>Clustering</i> de perfis acústicos	5
3.4.2	Classificação de género musical	6
3.4.3	Regressão da popularidade	7
3.5	Avaliação	8
4	Resultados e análise crítica	8
4.1	Leitura crítica do <i>clustering</i>	8
4.2	Leitura crítica da classificação de género	8
4.3	Relação entre <i>clustering</i> e classificação	9
4.4	Leitura crítica da regressão	9
4.5	Limitações	10
Parte II — Tarefa 2: Dataset Atribuído (Consumo Energético)		11
5	Domínio e objetivos	11
5.1	Domínio analisado	11
5.2	Objetivos	11
6	Metodologia SEMMA	11
6.1	Sample	12
6.2	Explore	12
6.3	Modify	12
6.4	Model	13
6.4.1	Classificação da taxa de consumo	13
6.4.2	Regressão do consumo total	13
6.5	Assess	13

7 Resultados e análise crítica	14
7.1 Classificação do consumo	14
7.2 Regressão do consumo	14
7.3 Limitações	14
8 Sugestões e recomendações	15
9 Reprodutibilidade	16
9.1 Tarefa 1 — Spotify Tracks	16
9.2 Tarefa 2 — Consumo Energético	16
10 Conclusão	16
Anexos	18

1 Introdução

O presente relatório documenta o trabalho desenvolvido no âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes, correspondente à componente prática de grupo. O objetivo central consistiu em conceber, implementar e avaliar modelos de aprendizagem automática sobre dois conjuntos de dados distintos, recorrendo à plataforma KNIME como ambiente de desenvolvimento e experimentação.

O trabalho estrutura-se em duas tarefas independentes, conforme definido no enunciado. A **Tarefa 1** incide sobre um **dataset de grupo** — um conjunto de dados sobre faixas musicais do Spotify, gerado sinteticamente para simular um cenário realista de preparação de dados. Nesta tarefa, a metodologia adotada foi o **CRISP-DM**, aplicando-se técnicas de *clustering* para identificação de perfis acústicos e modelos de regressão para previsão da popularidade das faixas. A **Tarefa 2** é dedicada a um **dataset atribuído** — um conjunto de dados sobre consumo energético e variáveis meteorológicas, distribuído pela equipa docente através do Blackboard. Nesta tarefa, seguiu-se a metodologia **SEMMA**, desenvolvendo-se modelos de classificação e de regressão com base nas relações entre variáveis climáticas e os padrões de consumo registados.

Cada tarefa é descrita em parte própria do relatório, com a respetiva fundamentação metodológica, descrição das fases de análise e modelação, e discussão crítica dos resultados. As figuras e tabelas mais extensas são remetidas para a secção de Anexos, sendo referenciadas ao longo do texto.

Parte I — Tarefa 1: Dataset de Grupo (Spotify Tracks)

2 Domínio e objetivos

2.1 Domínio analisado

O dataset `spotify_tracks.csv` foi gerado por um *script* Python especificamente concebido para simular um conjunto de dados realista sobre faixas musicais da plataforma Spotify. O ficheiro contém **100 500 registos** e **21 colunas**, cobrindo o período temporal de **2000 a 2024** e **20 géneros** musicais distintos. Cada registo representa uma faixa, caracterizada por atributos de identificação, variáveis de contexto editorial e um conjunto de *features* acústicas extraídas da API do Spotify.

O domínio analisado é o da análise musical e do consumo digital. As *features* acústicas — como `danceability`, `energy`, `loudness` e `acousticness` — capturam propriedades sonoras objetivas, enquanto variáveis como `genre`, `release_year` e `explicit` fornecem contexto editorial. O target principal é `popularity`, uma pontuação numérica entre 0 e 100.

O gerador não produziu um *dataset* limpo; pelo contrário, introduziu deliberadamente problemas de qualidade comuns em cenários reais de ciência de dados. Foram injetados valores em falta, *outliers* numéricos em várias colunas e 500 linhas duplicadas. Existe ainda um ficheiro auxiliar, `spotify_tracks_errors_log.csv`, que regista a localização exata de cada erro introduzido e serviu como referência para validação das etapas de preparação. A Tabela A.1 (Anexo 10) sintetiza a estrutura do dataset.

2.2 Objetivos

Os objetivos definidos para esta tarefa foram:

- garantir uma preparação robusta dos dados, com tratamento de duplicados, valores em falta, *outliers* e criação de atributos derivados;
- identificar perfis acústicos através de *k-means* e interpretar a composição dos *clusters* obtidos;
- treinar modelos de classificação para prever o género musical (`genre`, 20 classes) a partir das *features* acústicas, relacionando esta abordagem supervisionada com a segmentação não supervisionada do *clustering*;
- treinar modelos de regressão para prever `popularity` a partir das variáveis acústicas, de contexto e do género musical (codificado em *one-hot*);
- produzir uma análise crítica dos resultados, com foco na relação entre *clustering* e classificação, na contribuição do género para a regressão e no desempenho preditivo cruzado das três vertentes.

3 Metodologia CRISP-DM

A metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*) organiza o processo de análise de dados em seis fases iterativas: compreensão do negócio, compreensão dos dados, preparação dos dados, modelação, avaliação e *deployment*. Esta metodologia orientou a estrutura do *workflow* KNIME e a organização desta secção do relatório.

3.1 Compreensão do negócio

O objetivo analítico é duplo: caracterizar faixas musicais através de perfis acústicos (segmentação) e prever a popularidade com base nas propriedades sonoras e de contexto (regressão). Na prática, estes objetivos traduzem-se em casos de uso como segmentação de catálogo, recomendação musical e análise do grau em que os atributos de áudio explicam o sucesso comercial de uma faixa.

3.2 Compreensão dos dados

O bloco de *Data Understanding* do *workflow* foi implementado com 31 nós KNIME, organizados para cobrir todas as dimensões relevantes da qualidade dos dados. A leitura inicial, através do nó **CSV Reader** (#2), confirmou a importação de 100 500 linhas e 21 colunas, com as *features* de áudio corretamente interpretadas como numéricas.

O nó **Statistics** (#3) foi configurado para 12 colunas numéricas — **release_year**, **popularity**, **duration_ms**, **danceability**, **energy**, **loudness**, **speechiness**, **acousticness**, **instrumentalness**, **liveness**, **valence** e **tempo** — e revelou os sinais mais relevantes: valores em falta nas *features* de áudio, violações de domínio em variáveis limitadas ao intervalo $[0, 1]$ e extremos em **tempo**, **loudness** e **duration_ms**.

A componente categórica foi examinada com cinco nós **Value Counter**, cobrindo **genre** (20 géneros confirmados), **explicit**, **mode**, **key** e **time_signature**. A exploração univariada asentou em 12 histogramas e 7 *boxplots* (Figuras A.1 e A.2 no Anexo 10), que documentaram as distribuições das variáveis contínuas. As relações bivariadas foram analisadas com 4 gráficos de dispersão — pares **energy-loudness**, **energy-acousticness**, **danceability-valence** e **release_year-popularity** — e uma matriz de correlação linear sobre 15 colunas (Figura A.3 no Anexo 10).

A deteção de duplicados foi realizada através do par **GroupBy** (#40) + **Row Filter** (#39), que isolou 500 registos repetidos, confirmando a injeção de duplicados prevista pelo gerador.

Em síntese, esta fase demonstrou que o *dataset* continha, de forma inequívoca, os três tipos de problemas que a preparação subsequente teria de resolver: valores em falta, *outliers* e duplicados. A Tabela 1 resume a evidência recolhida.

3.3 Preparação dos dados

A preparação dos dados foi implementada como um pipeline sequencial com cinco etapas principais, executadas antes da separação entre os ramos de *clustering* e regressão. A Figura A.4 (Anexo 10) ilustra a configuração do pipeline no KNIME.

Tabela 1: Problemas de qualidade evidenciados na fase de compreensão dos dados

Problema	Evidência no workflow	Consequência
Valores em falta	Statistics e histogramas	Imputação em Missing Value
Valores fora de domínio	Statistics, <i>boxplots</i> e <i>scatter plots</i>	Sanitização em Expression
Extremos artificiais	tempo, loudness e duration_ms	Tratamento em Numeric Outliers
Duplicados	GroupBy e Row Filter isolam 500 casos	Remoção em Duplicate Row Filter

3.3.1 Remoção de duplicados

A primeira operação do pipeline é o nó **Duplicate Row Filter (#41)**, que compara todas as colunas exceto `track_id`, remove as linhas repetidas e conserva a primeira ocorrência. O resultado confirma a passagem de 100 500 para 100 000 linhas, eliminando os 500 duplicados.

3.3.2 Sanitização e engenharia de atributos

O nó **Expression (#42)** concentra num único ponto oito transformações que, num *workflow* menos compacto, estariam dispersas por múltiplos nós. As operações realizadas foram:

- conversão de valores fora do domínio $[0, 100]$ de `popularity` para *missing*;
- conversão de violações do intervalo $[0, 1]$ nas *features* de áudio (`danceability`, `energy`, `speechiness`, `acousticness`, `instrumentalness`, `liveness` e `valence`) para *missing*;
- conversão de valores inválidos de `key`, `mode` e `time_signature` para *missing*;
- codificação binária da variável `explicit` (`True` $\rightarrow$ 1, `False` $\rightarrow$ 0);
- criação do atributo derivado `duration_min` ($= \text{duration_ms} / 60\,000$), mais interpretável do que milissegundos;
- criação da classe auxiliar `popularity_class` com três níveis (Baixa, Média, Alta) para estratificação.

Esta etapa é metodologicamente relevante porque, em vez de eliminar precocemente as linhas problemáticas, opta por converter violações de domínio em valores em falta, delegando a decisão para o nó seguinte.

3.3.3 Imputação de valores em falta

O nó **Missing Value (#43)** recebe tanto os valores em falta originais do CSV como os gerados pelo **Expression**. A estratégia de imputação adotada não é uniforme, refletindo uma escolha ponderada por coluna:

- **Média:** `danceability`, `valence`.

- **Mediana:** `energy`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `loudness`, `tempo`, `duration_ms`.
- **Remover linha:** `popularity` (target).

Após esta fase, o *dataset* regista 99 353 linhas (menos 647 face às 100 000 anteriores), correspondendo às linhas cujo target `popularity` era inválido e não foi imputado.

3.3.4 Tratamento de *outliers*

Os *outliers* contínuos são tratados no nó `Numeric Outliers` (#45), que intervém sobre três colunas — `duration_ms`, `loudness` e `tempo` — utilizando o critério IQR com fator 3.0 e substituindo os valores extremos pelo limite admissível mais próximo. Esta abordagem preserva as linhas afetadas, evitando perda adicional de dados.

3.3.5 Seleção de variáveis e separação de ramos

O nó `Column Filter` (#47) reduz o *dataset* a 15 colunas, removendo identificadores (`track_id`, `track_name`, `artist_name`, `album_name`), colunas redundantes (`duration_ms`, substituída por `duration_min`), e os atributos `key` e `time_signature`. A coluna `genre`, ao contrário da versão anterior do *workflow*, é preservada em todos os ramos. A base comum resultante contém 99 353 linhas e 15 colunas, a partir da qual se abrem três ramos:

- **Ramo de *clustering*:** reduzido a 10 *features* acústicas normalizadas (Min-Max para $[0, 1]$) — sem género, que é reintroduzido apenas no pós-processamento para interpretação (`Joiner` (#136) por `RowID`);
- **Ramo de classificação:** filtra 11 colunas — as 10 *features* acústicas normalizadas mais o target `genre` — e divide-se em dois sub-ramos com partições independentes (70/30 para a rede neuronal, 80/20 para a *Random Forest*), ambas estratificadas por género com `seed=1`;
- **Ramo de regressão:** o nó `Expression` (#229) cria a variável auxiliar `popularity_class` (Baixa/Media/Alta) para estratificação. O nó `One to Many` (#221) codifica `genre` em 20 colunas binárias (*one-hot encoding*), expandindo o espaço de *features* para 34 colunas. Segue-se a partição treino/teste (80/20, estratificada por `popularity_class`, `seed=1`), normalização Min-Max sobre as *features* e remoção de `popularity_class` no treino e no teste. As *features* finais de regressão são 33 preditores — `release_year`, `explicit`, as 10 *features* de áudio, `mode`, `duration_min` e as 20 dummies de género — com target `popularity`.

3.4 Modelação

3.4.1 *Clustering* de perfis acústicos

Método do cotovelo. A seleção do número de *clusters* baseou-se no método do cotovelo. Foram executadas sete experiências de *k-means* para valores de $k \in \{3, 4, 5, 6, 7, 8, 9\}$, com inicialização aleatória, `seed=1` e 99 iterações máximas. Em cada ramo candidato, a soma das distâncias quadradas intra-*cluster* (WCSS) foi calculada manualmente: o nó `Joiner` associa cada ponto ao centróide do respetivo *cluster*, o nó `Math Formula` calcula a distância euclidiana quadrada às

10 coordenadas do centróide, e o nó **GroupBy** agrega os valores. As sete linhas de WCSS foram concatenadas e representadas graficamente (Figura A.5 no Anexo 10).

Modelo final. O modelo de *clustering* adotado fixou $k = 5$, coerente com a leitura da curva do cotovelo. O nó **k-Means** (#141) produz diretamente a coluna **Cluster**, dispensando um *assigner* separado. Os centróides foram transformados para formato longo (**Unpivot**) e visualizados num gráfico de barras agrupado (Figura A.6 no Anexo 10), que permite comparar o perfil acústico médio de cada *cluster* nas 10 *features* normalizadas.

Interpretação. A dimensão dos *clusters* foi calculada através de **GroupBy** (contagem por **Cluster**) e **Cross Joiner** (total global), obtendo-se a percentagem relativa de cada grupo. Para interpretação semântica, a coluna **genre** — que não integra o espaço de *features* do *clustering* — foi reintroduzida via **Joiner** por **RowID**, permitindo construir uma matriz **Cluster** $\times$ **Genre** com **Pivot** e um gráfico de barras empilhadas (Figura A.7 no Anexo 10).

3.4.2 Classificação de género musical

A novidade face à versão anterior do *workflow* é a inclusão de um ramo de classificação supervisionada que utiliza as mesmas 10 *features* acústicas que alimentam o *k-means*, mas com o objetivo de prever o género musical (20 classes). Este desenho permite contrastar diretamente a aprendizagem não supervisionada (agrupamento por semelhança acústica, sem conhecimento dos rótulos) com a aprendizagem supervisionada (classificação informada pelo género real), medindo até que ponto os atributos de áudio contêm sinal suficiente para discriminar estilos musicais.

Configuração. O ramo de classificação parte da base comum pós-preparação. O nó **Column Filter** (#220) isola 11 colunas: as 10 *features* acústicas e o target **genre**. A normalização Min-Max ($[0, 1]$) é aplicada através do nó **Normalizer** (#218), garantindo que todas as variáveis contribuem em escala comparável.

Foram treinados dois modelos supervisionados:

- **RProp MLP** (#226): rede neuronal *feedforward* com uma camada escondida de 30 neurónios, treinada com o algoritmo *RProp* durante 200 iterações (*seed*=1). A partição é 70/30 (treino/teste), estratificada por género, resultando em 70 000 exemplos de treino e 30 000 de teste.
- **Random Forest** (#235): *ensemble* de 200 árvores de decisão, critério Gini, amostragem de colunas em modo $\sqrt{\cdot}$ (*SquareRoot*), com *seed*=1. A partição é 80/20 (treino/teste), estratificada por género, resultando em 80 000 exemplos de treino e 20 000 de teste.

A escolha de partições diferentes (70/30 vs. 80/20) reflete uma preocupação metodológica: a MLP, por ser um modelo paramétrico com maior propensão ao sobreajustamento, beneficia de um conjunto de teste mais numeroso para validação fiável; a *Random Forest*, enquanto método de *ensemble*, tolera uma proporção de teste ligeiramente menor sem perda de robustez estatística.

Métricas. A avaliação foi realizada através do nó **Scorer**, que calcula a exatidão (*accuracy*), o erro, o número de classificações corretas e incorretas, e o coeficiente Kappa de Cohen (que corrige a exatidão pela probabilidade de acerto aleatório, sendo particularmente informativo em problemas com 20 classes). A matriz de confusão visualizada no *Heatmap* (#231) permite inspecionar quais os géneros mais frequentemente confundidos (Figura A.13 no Anexo 10).

A Tabela 2 sintetiza os resultados. A *Random Forest* atinge uma exatidão de **68.16%** (Kappa = 0.655), superando marginalmente a MLP com 67.67% (Kappa = 0.648). Ambos os valores de

Kappa, superiores a 0.64, indicam uma concordância substancial entre as previsões e os rótulos reais — um resultado expressivo considerando que se trata de 20 classes a partir de apenas 10 *features* exclusivamente acústicas.

Tabela 2: Métricas de classificação — Previsão de género musical

Modelo	Exatidão	Erro	Corretas	Incorretas	Kappa
RProp MLP (70/30)	0.6767	0.3233	20 302	9 698	0.6482
<i>Random Forest</i> (80/20)	0.6816	0.3184	13 632	6 368	0.6545

Relação com o *clustering*. A justaposição do ramo de classificação com o de *clustering* é metodologicamente reveladora. Ambos operam sobre exatamente as mesmas 10 *features* acústicas, mas com filosofias opostas:

- O *k-means* (não supervisionado) agrupa faixas por proximidade no espaço acústico, sem qualquer conhecimento dos géneros reais; a interpretação dos grupos é feita *a posteriori* através da distribuição dos géneros em cada *cluster*.
- A classificação (supervisionada) aprende a fronteira de decisão a partir dos rótulos de género, medindo diretamente a separabilidade acústica das 20 classes.

O coeficiente de *silhouette* de 0.16–0.18 obtido no *clustering* sugere uma separação modesta entre grupos, o que é coerente com uma exatidão de classificação de $\approx 68\%$: as *features* acústicas contêm sinal discriminativo genuíno — muito acima do acaso ($1/20 = 5\%$) — mas a sobreposição natural entre géneros impede uma separação nítida. Por outras palavras, o *clustering* encontra estrutura onde a classificação confirma que essa estrutura é informativa, mas não determinística.

A projeção PCA bidimensional das previsões da MLP (Figura A.12 no Anexo 10), com os pontos coloridos segundo o género previsto, permite visualizar a sobreposição entre classes que explica simultaneamente a *silhouette* modesta e a exatidão inferior a 100%.

3.4.3 Regressão da popularidade

Configuração. O ramo de regressão foi substancialmente expandido face à versão anterior. Além dos 13 preditores originais (`release_year`, `explicit`, as 10 *features* de áudio, `mode` e `duration_min`), o nó One to Many (#221) codifica os 20 géneros musicais em colunas binárias (*one-hot encoding*), totalizando **33 preditores**. Esta expansão é a concretização da hipótese de que o género musical transporta informação complementar às *features* acústicas para explicar a variabilidade da popularidade.

O nó Expression (#229) cria a variável auxiliar `popularity_class` (Baixa se `popularity` ≤ 29 , Média se ≤ 60 , Alta caso contrário) para estratificação da partição. A normalização Min-Max é aprendida no treino (79 482 linhas) e aplicada ao teste (19 871 linhas), sem fuga de informação. Foram treinados três modelos: regressão linear múltipla, árvore de regressão e *Random Forest*, todos com os 33 preditores e target `popularity`.

Regressão linear múltipla. O modelo linear, treinado com `Linear Regression Learner` (#163), inclui constante e utiliza todos os preditores disponíveis. As previsões foram avaliadas com `Numeric Scorer` (#165). O diagnóstico visual incluiu um gráfico de dispersão de valores reais *vs.* previstos e um histograma dos resíduos (Figuras A.15 e A.16 no Anexo 10).

Árvore de regressão. O modelo de árvore, treinado com `Simple Regression Tree Learner` (#166), foi configurado sem limitações explícitas de profundidade ou tamanho mínimo de nó, deixando a árvore crescer livremente. Os diagnósticos encontram-se nas Figuras A.18 e A.19 (Anexo 10).

Random Forest. O modelo de *Random Forest*, configurado no nó `Random Forest Learner (Regression)` (#172), utiliza 100 árvores, *seed*=1, *bootstrap* ativo e amostragem de colunas em modo $\sqrt{\cdot}$ (*SquareRoot*). Ao contrário da versão anterior do *workflow*, este ramo foi integralmente executado. Os gráficos de diagnóstico encontram-se nas Figuras A.21 e A.22 do Anexo 10.

3.5 Avaliação

A avaliação quantitativa da classificação baseou-se na exatidão, erro e coeficiente Kappa de Cohen, calculados sobre os conjuntos de teste através do nó `Scorer` (Tabela 2, apresentada na secção anterior). A avaliação da regressão baseou-se nas métricas R^2 , MAE e RMSE, calculadas sobre o conjunto de teste através do nó `Numeric Scorer`. A Tabela 3 sintetiza os valores observados para a regressão. A avaliação qualitativa é desenvolvida na secção de análise crítica (Secção 4).

Tabela 3: Métricas de regressão — Spotify Tracks (com género em *one-hot*)

Modelo	R^2	RMSE	MAE
Regressão linear	[a preencher]	[a preencher]	[a preencher]
Árvore de regressão	[a preencher]	[a preencher]	[a preencher]
<i>Random Forest</i>	[a preencher]	[a preencher]	[a preencher]

Valores a preencher após exportação dos *Numeric Scorers* (#165, #168, #174).

4 Resultados e análise crítica

4.1 Leitura crítica do *clustering*

Os resultados de *clustering* mostram que existe estrutura nos dados musicais, mas a separação entre grupos não é nítida. Um coeficiente de *silhouette* de 0.0883 no método hierárquico constitui um sinal de sobreposição relevante entre *clusters*, o que é consistente com a natureza do domínio: diferentes faixas podem partilhar níveis semelhantes de energia, valência e dançabilidade sem que isso se traduza em grupos radicalmente distintos. Em termos práticos, o *clustering* revela-se mais útil como ferramenta de segmentação exploratória do que como mecanismo de rotulagem rígida.

A análise dos centróides por *feature* permite identificar perfis sonoros diferenciados, e a composição dos *clusters* por género musical confirma que os agrupamentos capturam afinidades estilísticas genuínas, ainda que com sobreposição. A estabilidade dos valores de *silhouette* entre $k = 4$ e $k = 6$ (aproximadamente 0.16–0.18) sugere que a escolha de $k = 5$ representa um compromisso razoável entre granularidade da segmentação e coesão interna dos grupos.

4.2 Leitura crítica da classificação de género

Os modelos de classificação demonstram que as 10 *features* acústicas contêm sinal discriminativo substancial para a previsão do género musical. Uma exatidão de **68.2%** e um Kappa de **0.655**

(*Random Forest*) sobre 20 classes é um resultado expressivo, sobretudo quando se considera que a *baseline* aleatória é de apenas 5%. A proximidade entre a MLP (67.7%) e a *Random Forest* (68.2%) sugere que a capacidade preditiva está limitada pela própria informação contida nas *features* acústicas, e não pela flexibilidade do modelo — ambos os algoritmos convergem para um patamar semelhante de desempenho.

A análise da matriz de confusão (Figura A.13 no Anexo 10) revela que as confusões não são aleatórias, mas sim estruturadas por afinidade acústica: géneros com propriedades sonoras semelhantes (e.g., *hip-hop* e *R&B*, *rock* e *metal*, *electronic* e *pop*) são mais frequentemente trocados entre si. Este padrão é coerente com a intuição musical e, crucialmente, compatível com os resultados do *clustering*, onde estes mesmos géneros tendem a co-ocorrer nos mesmos grupos.

A projeção PCA das previsões (Figura A.12) confirma visualmente esta sobreposição: as diferentes classes formam manchas com contornos difusos, com algumas classes mais compactas e outras dispersas, refletindo a variabilidade intra-género das propriedades acústicas.

4.3 Relação entre *clustering* e classificação

A coexistência dos dois ramos sobre o mesmo espaço de *features* permite uma triangulação metodológica rara, com conclusões convergentes:

1. **Ambas as abordagens encontram sinal.** O *k-means* identifica 5 grupos acústicos não aleatórios (*silhouette* > 0). A classificação supervisionada recupera o género com $\approx 68\%$ de exatidão (muito acima dos 5% do acaso). Isto demonstra que as *features* acústicas do Spotify têm, de facto, poder discriminativo.
2. **A separação não é total.** A *silhouette* modesta (0.08–0.18) é a contrapartida não supervisionada da exatidão de classificação de 68% — ambas apontam para uma sobreposição intrínseca no espaço acústico que nenhum modelo, por mais flexível que seja, consegue eliminar.
3. **O *clustering* descobre agrupamentos que a classificação valida.** A matriz *cluster* $\times$ *género* (Figura A.7) mostra que géneros próximos no espaço acústico coabitam os mesmos *clusters*, e a matriz de confusão da classificação revela que as trocas entre géneros seguem precisamente este mesmo padrão de afinidade acústica. Esta convergência entre uma técnica não supervisionada e outra supervisionada reforça a validade de ambas.
4. **Limite fundamental da representação acústica.** O facto de um classificador supervisionado com acesso ao *ground truth* do género não ultrapassar os $\approx 68\%$ de exatidão estabelece um limite superior empírico para o que é possível extrair das 10 *features* de áudio. Este limite explica por que razão o *k-means* produz *clusters* com *silhouette* modesta: a própria representação dos dados impõe um teto à separabilidade.

4.4 Leitura crítica da regressão

A introdução do género musical como preditor (via *one-hot encoding*) na regressão da popularidade representa um enriquecimento relevante do espaço de *features*. Na versão anterior do *workflow* — que usava apenas os 13 preditores acústicos e de contexto — a regressão linear explicava apenas 1.8% da variância da popularidade ($R^2 = 0.018$). A inclusão dos 20 indicadores binários de género permite agora testar a hipótese de que certos géneros estão sistematicamente

associados a níveis de popularidade mais elevados ou mais baixos, independentemente das suas propriedades acústicas.

[A preencher com a análise concreta após obtenção dos novos valores de R^2 , RMSE e MAE dos três modelos de regressão. Incluir: (i) comparação do R^2 antes e depois da inclusão do género; (ii) quais os coeficientes do modelo linear com maior magnitude; (iii) se a *Random Forest* melhora significativamente face aos modelos mais simples; (iv) interpretação dos resíduos por género.]

Independentemente dos valores numéricos concretos, é expectável que a capacidade preditiva permaneça limitada, pois a popularidade de uma faixa musical é influenciada por fatores externos ao áudio e ao género — estratégias de marketing, notoriedade do artista, contexto cultural, exposição mediática e dinâmica de playlists — que o *dataset* atual não captura. O género musical, embora marginalmente mais informativo do que as *features* acústicas isoladas, não substitui estas variáveis de contexto sociocultural.

4.5 Limitações

A principal limitação é a natureza sintética do *dataset* que, embora gerado com distribuições inspiradas em dados reais, não substitui plenamente um catálogo musical autêntico. As relações entre *features* acústicas e popularidade podem ser artificialmente atenuadas ou amplificadas pelo processo de geração, e a distribuição dos géneros (uniforme, 20 géneros com igual representação) não reflete a realidade do mercado musical, onde géneros como *pop* e *hip-hop* dominam em volume de produção.

Adicionalmente, os valores de *silhouette* obtidos, embora coerentes entre os métodos hierárquico e *k-means*, variam com a amostragem (0.0883 em 5 000 registos vs. 0.16–0.18 em 20 000), o que sugere que a estimativa da qualidade do agrupamento é sensível ao tamanho e à composição da amostra. As métricas de regressão podem ainda ser influenciadas pelas estratégias de imputação e de tratamento de *outliers* adotadas na preparação.

Por fim, a arquitetura de três ramos paralelos (*clustering*, classificação, regressão) sobre o mesmo *dataset* introduz o risco de *data leakage* conceptual se as conclusões de um ramo forem usadas para justificar decisões noutra ramo sem o devido cuidado metodológico. A separação estrita dos fluxos no KNIME mitiga este risco operacionalmente, mas a independência analítica deve ser mantida na interpretação.

Parte II — Tarefa 2: Dataset Atribuído (Consumo Energético)

5 Domínio e objetivos

5.1 Domínio analisado

O dataset atribuído, disponibilizado pela equipa docente para os grupos de número ímpar, é composto por dois ficheiros: `consumption_dataset.csv` e `consumption_explanation.txt`. O conjunto de dados descreve medições de consumo de energia elétrica em diferentes níveis de tensão, conjugadas com variáveis meteorológicas recolhidas no mesmo intervalo temporal.

As variáveis de consumo distribuem-se por quatro níveis de tensão — **Very High Voltage** (kWh), **High Voltage** (kWh), **Medium Voltage** (kWh) e **Low Voltage** (kWh) — existindo ainda a coluna agregada **Total** (kWh). A coluna **Consumptions** constitui o target de classificação, representando a taxa de consumo categorizada em classes discretas.

O conjunto de variáveis meteorológicas é extenso e inclui temperatura (`temperature_2m`, `apparent_temperature`), humidade relativa (`relative_humidity_2m`), precipitação (`precipitation`, `rain`, `snowfall`), nebulosidade (`cloud_cover`), pressão atmosférica (`surface_pressure`), velocidade e direção do vento em várias altitudes (`wind_speed_10m`, `wind_speed_100m`, `wind_direction_10m`, `wind_direction_100m`, `wind_gusts_10m`), radiação (`Diffuse_Radiation`, `Direct_Radiation`, `terrestrial_radiation`) e uma coluna de identificação temporal (`Date/Time`).

O domínio analisado é o da gestão energética com suporte meteorológico. A relação entre condições atmosféricas e padrões de consumo elétrico tem relevância prática para previsão de carga, planeamento de capacidade e otimização de redes de distribuição. A Tabela A.2 (Anexo 10) apresenta a estrutura do dataset.

5.2 Objetivos

Os objetivos definidos para esta tarefa foram:

- explorar e preparar o *dataset* atribuído, tratando valores em falta, *outliers* e inconsistências de formato;
- desenvolver modelos de classificação para prever a classe **Consumptions** a partir das variáveis meteorológicas e de consumo;
- desenvolver modelos de regressão para prever o consumo total (**Total** (kWh)) ou uma das suas componentes;
- avaliar comparativamente os modelos e extrair conclusões sobre a relação entre clima e consumo energético.

6 Metodologia SEMMA

A metodologia SEMMA (*Sample, Explore, Modify, Model, Assess*), desenvolvida pelo SAS Institute, organiza o processo de análise de dados em cinco fases sequenciais. Ao contrário do

CRISP-DM, a SEMMA coloca maior ênfase nos aspetos técnicos da modelação e menos nas fases de compreensão do negócio e *deployment*, sendo particularmente adequada para projetos com um foco mais operacional. Esta metodologia orientou a estrutura do *workflow* KNIME do dataset atribuído e a organização desta secção.

6.1 Sample

A fase de *Sample* consiste na seleção e carregamento dos dados. O *dataset* foi importado através do nó **CSV Reader** do KNIME, que confirmou a estrutura tabular com as 24 colunas descritas no ficheiro de explicação. [Indicar aqui a dimensão observada do dataset após execução do workflow.]

Nesta fase, foi também realizada uma análise preliminar da distribuição temporal dos registos, verificando a cobertura do período de amostragem e a granularidade das observações (horária, diária ou outra). A estratificação inicial teve em conta a variável **target Consumptions**, assegurando representatividade das classes em qualquer partição futura.

6.2 Explore

A fase de *Explore* incidiu sobre a análise descritiva e visual dos dados, com o objetivo de compreender a distribuição das variáveis e identificar problemas de qualidade.

Foram produzidos histogramas e *boxplots* para as variáveis contínuas — temperaturas, humidade, precipitação, vento, pressão e radiação — bem como para os consumos energéticos por nível de tensão. A análise da variável **target Consumptions** incluiu a verificação das classes presentes e da sua distribuição, para detetar eventuais desequilíbrios.

A matriz de correlação entre variáveis meteorológicas e consumos (Figura A.25 no Anexo 10) permitiu uma primeira leitura das relações lineares mais fortes, orientando a seleção de *features* para a modelação. As variáveis qualitativas de radiação (**Diffuse_Radiation**, **Direct_Radiation**) foram inspecionadas quanto à cardinalidade e à relação com o consumo.

A qualidade dos dados foi avaliada através da contabilização de valores em falta por coluna e da deteção de *outliers* com base no IQR.

6.3 Modify

A fase de *Modify* corresponde à preparação e transformação dos dados. O pipeline implementado incluiu as seguintes operações:

- **Conversão temporal:** a coluna **Date/Time** foi convertida para um formato interpretável, permitindo a extração de componentes derivadas — hora, dia da semana, mês, estação do ano — que enriquecem o espaço de *features* e capturam padrões de sazonalidade.
- **Tratamento de valores em falta:** as variáveis contínuas foram imputadas com a mediana (robusta a *outliers*); as linhas com **target Consumptions** em falta foram removidas.
- **Tratamento de outliers:** as variáveis contínuas foram inspecionadas com base no IQR (fator 3.0) e os valores extremos foram truncados para o limite admissível.
- **Codificação de variáveis qualitativas:** as colunas **Diffuse_Radiation** e **Direct_Radiation** foram codificadas numericamente.

- **Normalização:** as variáveis contínuas foram submetidas a normalização Min-Max para o intervalo $[0, 1]$.
- **Partição treino/teste:** o *dataset* foi dividido em treino (80%) e teste (20%), com estratificação pela variável **Consumptions**.
- **Separação de ramos:** foram criados dois ramos independentes — um para classificação (target **Consumptions**) e outro para regressão (target **Total (kWh)**).

Os detalhes das configurações e as imagens do pipeline encontram-se no Anexo 10.

6.4 Model

A fase de *Model* abrangeu a concepção e o treino dos modelos preditivos, organizados em duas vertentes:

6.4.1 Classificação da taxa de consumo

Para a classificação do target **Consumptions**, foram experimentados os seguintes algoritmos:

- **Árvore de decisão:** *baseline* interpretável, permitindo inspecionar as regras de decisão e a importância relativa das *features*;
- **Random Forest:** modelo de *ensemble* com 100 árvores, *seed*=1, *bootstrap* ativo e amostragem de colunas em modo *SquareRoot*;
- **Regressão logística multinomial:** *baseline* linear para classificação multiclasse.

A avaliação baseou-se nas métricas de exatidão, precisão, *recall* e F_1 (macro e ponderado), calculadas sobre o conjunto de teste. A matriz de confusão foi produzida para cada modelo, permitindo identificar que classes são mais frequentemente confundidas.

6.4.2 Regressão do consumo total

Para a regressão do **Total (kWh)**, foram experimentados:

- **Regressão linear múltipla:** *baseline* com todas as *features* meteorológicas e temporais;
- **Árvore de regressão:** para capturar relações não lineares entre clima e consumo;
- **Random Forest:** modelo de *ensemble* potencialmente mais robusto.

As métricas de avaliação (R^2 , MAE, RMSE) foram calculadas sobre o conjunto de teste. Gráficos de valores reais *vs.* previstos e histogramas de resíduos foram produzidos para cada modelo.

[A preencher com os resultados concretos após execução do workflow.]

6.5 Assess

A fase de *Assess* corresponde à avaliação final dos modelos e à interpretação dos resultados. Esta avaliação é desenvolvida na secção de análise crítica (Secção 7).

A Tabela A.3 (Anexo 10) sintetiza as métricas comparativas dos modelos testados. Adicionalmente, foi realizada uma análise de importância de *features* para o modelo *Random Forest*, identificando as variáveis meteorológicas mais determinantes para o consumo.

7 Resultados e análise crítica

7.1 Classificação do consumo

[A preencher com a análise dos resultados de classificação. Incluir: (i) quais as classes mais difíceis de discriminar, com base na matriz de confusão; (ii) que *features* meteorológicas se revelaram mais relevantes para a classificação; (iii) comparação do desempenho entre os algoritmos testados e justificação para o modelo selecionado.]

7.2 Regressão do consumo

[A preencher com a análise dos resultados de regressão. Incluir: (i) a capacidade das variáveis meteorológicas para explicar a variabilidade do consumo total; (ii) comparação entre modelos lineares e não lineares; (iii) interpretação dos resíduos e identificação de padrões temporais não capturados.]

7.3 Limitações

O dataset de consumo energético, sendo real, pode apresentar limitações de cobertura temporal ou geográfica que condicionam a generalização dos modelos. A granularidade temporal das observações influencia a capacidade de capturar padrões sazonais e tendências de longo prazo, e a presença de variáveis qualitativas de radiação pode introduzir ruído se a codificação não for adequada.

8 Sugestões e recomendações

Com base nos resultados obtidos e na experiência de desenvolvimento dos *workflows*, formulam-se as seguintes recomendações.

Tarefa 1 (Spotify Tracks):

- testar diferentes valores de k e de *seed* para avaliar a estabilidade dos *clusters*;
- aprofundar a análise da matriz de confusão da classificação, identificando as confusões de género mais frequentes e a sua relação com as distâncias entre centróides dos *clusters*;
- testar arquiteturas alternativas para a MLP (e.g., duas camadas escondidas, *dropout*, regularização L_2) para verificar se o patamar de $\approx 68\%$ de exatidão é ultrapassável com modelos mais expressivos;
- experimentar afinação de hiperparâmetros (profundidade da árvore, número de estimadores, taxa de aprendizagem do RProp) para reduzir o sobreajustamento tanto na classificação como na regressão;
- analisar o erro de regressão por género musical, para quantificar se o *one-hot encoding* do género melhora ou apenas redistribui o erro;
- comparar o R^2 da regressão com e sem género, isolando a contribuição marginal deste preditor categórico.

Tarefa 2 (Consumo Energético):

- explorar a criação de *features* temporais adicionais — *lag* de consumo, médias móveis, indicadores de fim de semana ou feriado — que possam capturar padrões de sazonalidade e dependência temporal;
- investigar a utilidade preditiva das variáveis de radiação qualitativa após diferentes esquemas de codificação;
- realizar uma análise de importância de *features* para identificar que variáveis meteorológicas são mais determinantes para o consumo, orientando futuras recolhas de dados.

Recomendações transversais:

- consolidar as métricas de cada tarefa numa tabela-resumo única, facilitando a comparação entre algoritmos e a comunicação dos resultados;
- documentar os *workflows* com anotações internas no KNIME, para que a reprodutibilidade não dependa exclusivamente do relatório;
- explorar a utilização de componentes KNIME para encapsular pipelines reutilizáveis (preparação, normalização), promovendo a modularidade entre tarefas.

9 Reprodutibilidade

9.1 Tarefa 1 — Spotify Tracks

Ficheiros necessários:

- `src/grupo/dataset/spotify_tracks.csv` — dataset principal;
- `src/grupo/dataset/spotify_tracks_errors_log.csv` — registo de erros injetados;
- `src/grupo/dataset/create_dataset.py` — *script* de geração;
- `src/grupo/grupo.knwf` — *workflow* KNIME.

Procedimento: (1) abrir `grupo.knwf` e confirmar caminhos dos ficheiros CSV; (2) executar o bloco de *Data Understanding*; (3) executar o pipeline de preparação (Duplicate Row Filter (#41), Expression (#42), Missing Value (#43), Numeric Outliers (#45), Column Filter (#47)); (4) executar os ramos de *clustering* (k-Means (#141), PCA, Silhouette Coefficient), classificação (Column Filter (#220) → Normalizer (#218) → RProp MLP (#226) / Random Forest (#235)) e regressão (Expression (#229) → One to Many (#221) → Table Partitioner (#51) → modelos); (5) consultar as vistas dos nós Numeric Scorer, Scorer, Silhouette Coefficient e gráficos de diagnóstico.

9.2 Tarefa 2 — Consumo Energético

Ficheiros necessários:

- `src/atribuido/dataset/consumption_dataset.csv` — dataset principal;
- `src/atribuido/dataset/consumption_explanation.txt` — descrição das variáveis;
- `src/atribuido/atribuido.knwf` — *workflow* KNIME.

Procedimento análogo ao da Tarefa 1: abrir o *workflow*, executar o bloco exploratório (SEMMA *Explore*), o pipeline de preparação (*Modify*) e os ramos de classificação e regressão (*Model* e *Assess*).

10 Conclusão

O trabalho desenvolvido demonstra a aplicação prática de duas metodologias de análise de dados — CRISP-DM e SEMMA — a problemas com naturezas distintas: um *dataset* sintético de faixas musicais (Spotify) e um *dataset* real de consumo energético com variáveis meteorológicas. Em ambos os casos, o processo completo foi implementado, desde a compreensão do problema e exploração dos dados até à preparação, modelação e avaliação crítica.

Na Tarefa 1, o *clustering* permitiu identificar cinco perfis acústicos diferenciados, interpretáveis por género musical, ainda que com sobreposição natural entre estilos. A classificação supervisionada do género, com base nas mesmas *features* acústicas, atingiu $\approx 68\%$ de exatidão (Kappa ≈ 0.65), validando a existência de sinal discriminativo genuíno nas propriedades de áudio e estabelecendo um limite superior empírico para a separabilidade dos géneros. A regressão da

popularidade foi enriquecida com o *one-hot encoding* do gênero, permitindo quantificar a contribuição marginal desta variável para a previsão do sucesso comercial — embora, por natureza, a popularidade dependa de fatores socioculturais que transcendem o áudio e o gênero.

Na Tarefa 2, a combinação de modelos de classificação e regressão proporcionou uma dupla perspectiva sobre o problema do consumo energético: por um lado, a categorização dos níveis de procura em função das condições meteorológicas; por outro, a previsão quantitativa do consumo total. A integração de variáveis climáticas e temporais enriqueceu o espaço de *features* e mostrou-se promissora para aplicações de previsão de carga.

Globalmente, o trabalho evidencia a importância de uma preparação de dados rigorosa como pré-condição para qualquer modelação credível, e sublinha que a escolha e a configuração dos algoritmos devem ser guiadas tanto pelas métricas quantitativas como pela interpretabilidade dos resultados.

Anexos

A.1 — Imagens da Tarefa 1 (Spotify Tracks)




Figura A.1: Exploração univariada — histogramas e distribuições das variáveis numéricas do dataset Spotify

A.2 — Tabelas da Tarefa 1 (Spotify Tracks)

A.3 — Imagens da Tarefa 2 (Consumo Energético)

[As imagens do *workflow* de consumo energético serão inseridas nesta secção após a conclusão da execução e captura dos gráficos no KNIME.]

A.4 — Tabelas da Tarefa 2 (Consumo Energético)




Figura A.2: *Boxplots* e análise de dispersão inicial — detecção de *outliers*

Tabela A.1: Estrutura do dataset de grupo (Spotify Tracks)

Grupo de variáveis	Exemplos
Identificação	track_id, track_name, artist_name, album_name
Contexto editorial	release_year, genre, explicit, key, mode, time_signature
Target	popularity
<i>Features</i> de áudio	danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo, duration_ms



Figura A.3: Relações bivariadas entre *features* acústicas — gráficos de dispersão




Figura A.4: Pipeline de preparação de dados no KNIME (Tarefa 1)




Figura A.5: Método do cotovelo — curva de WCSS para $k \in \{3, \dots, 9\}$




Figura A.6: Centróides dos *clusters* por *feature* (formato longo, gráfico de barras)




Figura A.7: Distribuição dos géneros musicais por *cluster*




Figura A.8: Projeção PCA dos pontos e dos centróides (duas primeiras componentes)

Figura A.9: *Silhouette* para $k = 4$ Figura A.10: *Silhouette* para $k = 5$


Figura A.11: *Silhouette* para $k = 6$

Tabela A.2: Estrutura do dataset atribuído (Consumo Energético)

Grupo	Variáveis
Identificação temporal	RowID, Date/Time
Consumo elétrico	Very High Voltage (kWh), High Voltage (kWh), Medium Voltage (kWh), Low Voltage (kWh), Total (kWh)
Target (classificação)	Consumptions
Temperatura	temperature_2m (°C), apparent_temperature (°C)
Humidade e precipitação	relative_humidity_2m (%), precipitation (mm), rain (mm), snowfall (cm)
Pressão e nebulosidade	surface_pressure (hPa), cloud_cover (%)
Vento	wind_speed_10m (km/h), wind_speed_100m (km/h), wind_direction_10m (°), wind_direction_100m (°), wind_gusts_10m (km/h)
Radiação	Diffuse_Radiation, Direct_Radiation, terres- trial_radiation (W/m ²)




Figura A.12: Projeção PCA das previsões de género — classificação via RProp MLP (pontos coloridos por género previsto, 20 classes)

Tabela A.3: Métricas comparativas — Consumo Energético [a preencher]				
Modelo	Métrica 1	Métrica 2	Métrica 3	Métrica 4
<i>Classificação (target: Consumptions)</i>				
Árvore de decisão	[]	[]	[]	[]
<i>Random Forest</i>	[]	[]	[]	[]
Regressão logística	[]	[]	[]	[]
<i>Regressão (target: Total (kWh))</i>				
	R^2	RMSE	MAE	
Regressão linear	[]	[]	[]	
Árvore de regressão	[]	[]	[]	
<i>Random Forest</i>	[]	[]	[]	




Figura A.13: Matriz de confusão e métricas de classificação (*Scorer* #224 e #237, *Heatmap* #231)




Figura A.14: Ramo de regressão no KNIME (Tarefa 1) — com *one-hot encoding* de género




Figura A.15: Regressão linear: valores reais *vs.* previstos




Figura A.16: Regressão linear: distribuição dos resíduos



Figura A.17: Métricas da regressão linear (R^2 , MAE, RMSE)



Figura A.18: Árvore de regressão: valores reais *vs.* previstos




Figura A.19: Árvore de regressão: distribuição dos resíduos



Figura A.20: Métricas da árvore de regressão (R^2 , MAE, RMSE)



Figura A.21: *Random Forest*: valores reais *vs.* previstos




Figura A.22: *Random Forest*: distribuição dos resíduos



Figura A.23: Métricas da *Random Forest* (R^2 , MAE, RMSE)




Figura A.24: Pipeline de preparação no KNIME (Tarefa 2) — a inserir



Figura A.25: Matriz de correlação (Tarefa 2) — a inserir