

Relatorio de Resultados

Dataset de Grupo: Spotify Tracks

Analise de Dados e Modelacao em KNIME

Unidade Curricular: Analise e Descoberta de Informacao

Grupo: [Preencher]

Elementos: [Preencher]

May 4, 2026

Contents

1	Introducao	1
2	 dominio, objetivos e abordagem	1
2.1	dominio analisado	1
2.2	Objetivos	1
2.3	Estrategia seguida	1
3	 Metodologia de analise de dados	2
4	 Descricao do dataset	2
4.1	Estrutura geral	2
4.2	Qualidade dos dados	3
4.3	Exploracao inicial	3
5	 Preparacao dos dados em KNIME	5
5.1	Remocao de duplicados	5
5.2	Sanitizacao e engenharia de atributos	5
5.3	Tratamento de valores em falta	5
5.4	Tratamento de outliers	6
5.5	Selecao de variaveis e separacao de ramos	6
6	 Modelacao	7
6.1	Clustering	7
6.2	Regressao	10
7	 Resultados e analise critica	13
7.1	Resumo dos resultados mais relevantes	13
7.2	Leitura critica do clustering	13
7.3	Leitura critica da regressao	13
7.4	Limitações do estudo	14
8	 Sugestoes e recomendacoes	14
9	 Reprodutibilidade	14
10	 Conclusao	15

1 Introducao

Este relatorio documenta, de forma unica e coerente, o trabalho desenvolvido sobre o **dataset de grupo** selecionado no projeto, com implementacao em *workflows* KNIME e enquadramento no metodo CRISP-DM. O objetivo nao foi apenas construir modelos, mas sim mostrar todo o percurso analitico: compreensao do problema, compreensao dos dados, preparacao, modelacao, avaliacao e interpretacao critica dos resultados.

O problema analisado centra-se num conjunto de faixas musicais do ecossistema Spotify, com metadados editoriais, atributos acusticos e uma variavel alvo de interesse ligada a popularidade. A partir deste contexto, foram exploradas duas linhas de trabalho complementares. A primeira procura agrupar faixas em perfis sonoros semelhantes, usando *clustering* e analise de dimensionalidade. A segunda pretende prever a popularidade das faixas por regressao, comparando modelos lineares e nao lineares. Em paralelo, o workflow inclui ainda uma experiencia auxiliar de classificacao por rede neuronal, usada como verificacao adicional da separabilidade dos grupos obtidos.

O texto foi escrito para suportar a reproducao do trabalho e para refletir o que esta realmente implementado no workflow, evitando descricoes genericas ou passos que nao estejam presentes no projeto.

2 Dominio, objetivos e abordagem

2.1 Dominio analisado

O dominio escolhido e o da analise musical e de consumo digital. Neste contexto, as caracteristicas acusticas das faixas podem ser usadas para segmentacao editorial, recomendacao e estudo de perfis sonoros. Variaveis como **danceability**, **energy**, **loudness**, **acousticness** e **tempo** capturam propriedades com interpretacao musical direta, enquanto **genre**, **release_year** e **explicit** acrescentam contexto de catalogo.

2.2 Objetivos

Os objetivos do trabalho podem resumir-se em quatro pontos. Primeiro, analisar a qualidade do dataset e demonstrar os problemas existentes antes da modelacao. Segundo, construir um pipeline de preparacao robusto, capaz de remover duplicados, tratar valores em falta, controlar outliers e criar variaveis derivadas. Terceiro, conceber e comparar varios modelos de machine learning adequados ao problema de segmentacao e previsao. Quarto, produzir uma leitura critica dos resultados, identificando o que o workflow ja demonstra com solidez e o que ainda poderia ser aprofundado.

2.3 Estrategia seguida

A estrategia adotada foi deliberadamente iterativa. A leitura inicial do dataset orientou a preparacao dos dados; a preparacao definiu quais as features disponiveis para os modelos; e a modelacao devolveu evidencia que voltou a influenciar a interpretacao do dataset. Esta forma de trabalho e totalmente consistente com CRISP-DM, porque permite voltar atras sempre que a analise revela problemas de qualidade ou de interpretacao.

3 Metodologia de analise de dados

Neste projeto foi aplicado o metodo **CRISP-DM** (Cross-Industry Standard Process for Data Mining). O seu valor aqui e sobretudo pratico: cada fase responde a uma pergunta concreta e gera artefactos que alimentam a fase seguinte.

Na fase de **compreensao do problema**, foi definida a finalidade analitica do dataset de grupo: identificar perfis musicais coerentes e estimar a popularidade das faixas. Na fase de **compreensao dos dados**, o workflow confirmou a estrutura do CSV, mediu a distribuicao das variaveis e expôs problemas como faltas, outliers, intervalos de dominio violados e duplicados completos.

A fase de **preparacao** foi a mais rica tecnicamente. Em vez de aplicar uma limpeza superficial, o workflow faz uma sanitizacao controlada: primeiro remove duplicados, depois converte e corrige campos invalidos, em seguida imputa valores em falta e so depois trata extremos numericos. Este encadeamento e importante porque evita que os modelos aprendam com ruido desnecessario e permite manter a maior quantidade possivel de informacao util.

Na fase de **modelacao**, foram construidos ramos distintos para clustering e regressao. O clustering foi avaliado com o metodo do cotovelo, silhouette e PCA, enquanto a regressao foi suportada por treino/teste estratificado, normalizacao e comparacao entre regressao linear, arvore de regressao e um ramo de random forest ainda por executar.

Na fase de **avaliacao**, o foco nao foi apenas a qualidade numerica dos modelos, mas tambem a interpretacao do seu significado: se os clusters sao realmente separaveis, se a regressao linear e suficiente ou se existem evidencias de nao linearidade, e quao robusta e a preparacao perante dados fora de dominio.

4 Descricao do dataset

4.1 Estrutura geral

O ficheiro `spotify_tracks.csv` contem **100 500 registos** e **21 colunas**. O periodo temporal abrangido vai de **2000 a 2024** e o dataset cobre **20 generos** musicais. Existe ainda um ficheiro complementar, `spotify_tracks_errors_log.csv`, que regista os erros introduzidos intencionalmente no processo de geracao do dataset, o que foi essencial para validar a preparacao de dados.

Table 1: Estrutura do dataset de grupo

Grupo de variaveis	Exemplos
Identificacao	<code>track_id</code> , <code>track_name</code> , <code>artist_name</code> , <code>album_name</code>
Contexto	<code>release_year</code> , <code>genre</code> , <code>explicit</code> , <code>key</code> , <code>mode</code> , <code>time_signature</code>
Target	<code>popularity</code>
Audio	<code>danceability</code> , <code>energy</code> , <code>loudness</code> , <code>speechiness</code> , <code>acousticness</code> , <code>instrumentalness</code> , <code>liveness</code> , <code>valence</code> , <code>tempo</code> , <code>duration_ms</code>

4.2 Qualidade dos dados

O dataset não foi criado para ser limpo; foi criado para simular um ambiente realista de preparação. O gerador introduz valores em falta, outliers, violações de domínio e duplicados. Isto significa que a análise não podia começar diretamente pela modelação. Era necessário demonstrar, com evidência, que os problemas estavam identificados e que o workflow sabia resolvê-los de forma consistente.

Em termos práticos, os problemas mais relevantes são os seguintes. Existem valores em falta nas features de áudio, o que afeta tanto a análise exploratória como a modelação. Existem linhas duplicadas completas, que distorcem contagens, distribuições e treino de modelos. Existem ainda valores fora do domínio esperado em variáveis limitadas a intervalos bem definidos, como as features normalizadas entre 0 e 1, e outliers fortes em variáveis como `tempo`, `loudness` e `duration_ms`.

4.3 Exploração inicial

A fase de exploração foi organizada em torno de vários blocos visuais no KNIME. O objetivo era verificar rapidamente se o dataset estava lido corretamente, perceber a forma das distribuições e encontrar sinais de problemas a tratar.



Figure 1: Exploração univariada do dataset Spotify

[INSERIR IMAGEM KNIME]

Figure 2: Outliers e dispersao inicial

[INSERIR IMAGEM KNIME]

Figure 3: Relacoes bivariadas entre features acusticas

[INSERIR IMAGEM KNIME]

Figure 4: Representatividade por genero

A exploracao mostrou que as variaveis acusticas tinham escalas muito diferentes, o que e natural, mas tambem confirmou que havia varios pontos de anomalia a tratar. Por exemplo,

alguns valores de `danceability`, `valence` ou `energy` surgem fora do intervalo esperado. Em paralelo, o comportamento de `tempo` e `loudness` inclui valores extremos que justificam tratamento específico. Esta leitura inicial explica porque o workflow não passa diretamente da leitura do CSV para a modelação.

5 Preparação dos dados em KNIME

A preparação foi desenhada como um pipeline sequencial, onde cada nó acrescenta uma operação concreta ao estado dos dados.

5.1 Remoção de duplicados

O primeiro passo foi o **Duplicate Row Filter**. A escolha de tratar duplicados antes de qualquer outra transformação evita que a limpeza ou a imputação sejam aplicadas duas vezes aos mesmos registos. O workflow compara praticamente todas as colunas relevantes e conserva a primeira ocorrência, mantendo a ordem original. O resultado observado é claro: de 100 500 linhas iniciais, o dataset passa para 100 000 linhas, o que confirma a existência de 500 duplicados removidos no início do pipeline.

5.2 Sanitização e engenharia de atributos

Depois dos duplicados, o nó **Expression** concentra várias operações que poderiam estar espalhadas por mais nós. Aqui são feitas três coisas muito importantes. Primeiro, valores inválidos em variáveis limitadas a domínios conhecidos são convertidos em missing para serem resolvidos mais tarde com regra consistente. Segundo, a variável `explicit` é transformada para uma representação numérica binária. Terceiro, são criadas features derivadas como `duration_min` e a classe auxiliar `popularity_class`.

Esta etapa é crucial porque transforma o dataset num formato mais adequado à aprendizagem automática sem perder a informação original de contexto. A criação de `duration_min` torna a duração mais interpretável do que `duration_ms`, e a variável `popularity_class` permite estratificar o split de treino/teste e apoiar a leitura dos resultados.

5.3 Tratamento de valores em falta

O nó **Missing Value** recebe tanto os missing originais do CSV como os que são gerados pelo passo anterior. A estratégia não é uniforme; é precisamente essa diferença que mostra maturidade metodológica. Para algumas features, o workflow usa média; para outras, mediana; e para o target `popularity`, a linha é removida quando o valor está em falta.

Table 2: Estrategias de imputacao no no Missing Value

Coluna	Estrategia
danceability	Mean
valence	Mean
energy, speechiness, acousticness, instrumentalness, liveness, loudness, tempo, duration_ms	Median
popularity	Remove Row

Depois desta fase, o dataset fica com 99 353 linhas. O valor e importante porque confirma que a preparacao nao removeu tudo indiscriminadamente; removeu apenas o que era metodologicamente necessario remover.

5.4 Tratamento de outliers

Os outliers continuos sao tratados num no especifico, **Numeric Outliers**, que opera sobre `duration_ms`, `loudness` e `tempo`. O criterio de deteccao e o IQR, com scalar 3.0, e a acao escolhida e substituir o valor fora de intervalo pelo limite admissivel mais proximo. Esta decisao e relevante porque preserva a linha e impede que observacoes extremas deformem a modelacao.

5.5 Selecao de variaveis e separacao de ramos

Depois da limpeza principal, o workflow organiza uma base comum com 15 colunas. Nela permanecem as variaveis que sao uteis para clustering e regressao, incluindo `release_year`, `explicit`, `danceability`, `energy` e `loudness`. Tambem sao mantidas `tempo`, `duration_min` e a classe auxiliar `popularity_class`. Ficam de fora identificadores textuais e metadados menos uteis para modelacao direta.

A partir daqui o workflow divide-se em dois ramos. No ramo de clustering, o espaco e reduzido para 10 features sonoras e depois normalizado por Min-Max para o intervalo [0,1]. No ramo de regressao, o dataset e separado em treino e teste com split estratificado de 80/20 sobre `popularity_class`, e ambos os subconjuntos sao normalizados de forma consistente. O uso de **Table Partitioner** com seed fixa garante reprodutibilidade.



Figure 5: Pipeline de preparacao no KNIME



Figure 6: Preparacao final para modelacao

6 Modelacao

6.1 Clustering

O clustering procura agrupar faixas com perfis sonoros semelhantes. Para isso o workflow usa apenas as features acusticas normalizadas, o que e a opcao correta porque o objetivo nao e agrupar por ano, genero ou identificador, mas sim por assinatura sonora.

Metodo do cotovelo

A escolha do numero de clusters foi analisada com varias execucoes de k-Means para valores de k entre 3 e 9. O workflow nao usa uma funcao automatica pronta para o elbow; em vez disso, reconstrói manualmente a soma das distancias quadradas dentro de cada cluster e agrega os resultados num grafico de linha. Esse detalhe e importante porque mostra que a decisao de k nao foi arbitraria: foi suportada por uma curva de WCSS produzida no proprio KNIME.



Figure 7: Metodo do cotovelo

k-Means final

O modelo final de clustering foi fixado em **5 clusters**, com inicializacao aleatoria, seed 1 e maximo de 99 iteracoes. O output do proprio no inclui a coluna de cluster, pelo que nao foi necessario um assigner separado. Esta decisao final e coerente com a leitura da curva do elbow e com a interpretacao posterior dos centroides.



Figure 8: Clusters projetados em duas dimensoes



[INSERIR IMAGEM KNIME]

Figure 9: Centroides dos clusters

Interpretacao dos clusters

Para tornar os clusters interpretaveis, o workflow devolve os centroides a forma longa, cria graficos de barras e junta o genero musical para verificar composicao de cada grupo. Esta parte e essencial porque um cluster sem leitura semantica tem pouco valor analitico. Aqui a interpretacao passa a ser musical: clusters mais energeticos e dançaveis podem representar uma classe de faixas com uso mais intenso de ritmo, enquanto clusters com maior acustica e menor energia podem corresponder a perfis mais calmos ou instrumentais.

A qualidade do agrupamento foi analisada adicionalmente com silhouette. O metodo hierarquico sobre uma amostra obteve um valor medio global de aproximadamente **0.0732**, o que e baixo e sugere sobreposicao entre grupos. Em ramos de amostragem estratificada por cluster, surgem valores de cerca de **0.1609**, **0.1782** e **0.1740**, que continuam modestos mas sao superiores ao primeiro valor observado. Isto mostra que o clustering tem utilidade exploratoria, mas nao apresenta separacao perfeita entre classes sonoras.



[INSERIR IMAGEM KNIME]

Figure 10: Silhouette e qualidade do agrupamento



[INSERIR IMAGEM KNIME]

Figure 11: Distribuicao dos generos por cluster

Comparacao hierarquica

O workflow inclui ainda um ramo de clustering hierarquico com distancia euclidiana e linkage complete. Este ramo nao substitui o k-Means final, mas serve para comparar a qualidade da segmentacao. A leitura critica deste valor de silhouette e importante: o objetivo nao e apenas escolher um algoritmo, mas perceber se a estrutura dos dados suporta clusters nitidos ou se existe uma sobreposicao natural entre estilos musicais.

6.2 Regressao

O segundo objetivo de modelacao e prever **popularity**. Ao contrario do clustering, aqui ha uma variavel target numerica e, por isso, a interpretacao dos resultados passa pela qualidade da previsao e nao pela separacao entre grupos.

Regressao linear

O primeiro baseline e uma regressao linear multipla. O learner usa **popularity** como target e inclui constante. A vantagem deste modelo e a interpretabilidade: se o comportamento da popularidade for aproximadamente linear, este baseline pode ser suficiente. O workflow inclui ainda grafico de dispersao entre valores reais e previstos e histogramas de residuos para verificar se os erros estao centrados e se ha padroes sistematicos nao capturados.



[INSERIR IMAGEM KNIME]

Figure 12: Regressao linear: real vs previsto



[INSERIR IMAGEM KNIME]

Figure 13: Residuos da regressao linear

Arvore de regressao

Como alternativa nao linear, o workflow inclui uma simple regression tree. Os limites da arvore estao praticamente abertos, sem poda agressiva, o que lhe permite capturar limiares e interacoes locais. Este modelo e particularmente util quando a popularidade depende de zonas especificas do espaco de features, e nao apenas de efeitos globais lineares.



Figure 14: Comparacao de modelos de regressao



Figure 15: Analise de residuos da arvore

Random forest de regressao

Existe ainda um ramo de random forest de regressao configurado com 100 arvores, seed 1 e bootstrap ativo, mas nao executado na versao atual do workflow. Isto nao invalida o relatorio; pelo contrario, mostra que a comparacao de modelos esta montada para evoluir. Do ponto de vista analitico, o ramo sugere uma proximidade metodologica a uma comparacao mais rica entre modelos lineares e ensembles, que seria o passo seguinte natural.

Experiencia auxiliar de classificacao

O workflow inclui ainda uma branch auxiliar de classificacao com RProp MLP para prever o cluster. Esta experiencia nao e o foco principal do projeto, mas tem um papel util: verifica se os clusters obtidos sao suficientemente separados para serem aprendidos por um classificador. O modelo atingiu **accuracy de 0.9652418976**, com **Cohen's kappa de 0.9538043842**, o que indica uma separabilidade elevada dos grupos obtidos pelo clustering.

7 Resultados e análise crítica

7.1 Resumo dos resultados mais relevantes

Table 3: Resumo dos principais resultados observados

Elemento	Resultado observado
Tamanho inicial do dataset	100 500 registos e 21 colunas
Duplicados removidos	500 linhas
Base comum apos preparacao	99 353 linhas e 15 colunas
Ramo de clustering	99 353 linhas e 10 features normalizadas
Split treino/teste	80/20, estratificado por <code>popularity_class</code> , seed 1
Silhouette hierarquico	aproximadamente 0.0732
Silhouettes adicionais	aproximadamente 0.1609, 0.1782 e 0.1740
Cluster final	$k = 5$
Classificador auxiliar do cluster	accuracy de 0.9652418976

7.2 Leitura crítica do clustering

Os resultados de clustering mostram que existe estrutura nos dados, mas a separação não é perfeita. Um silhouette perto de 0.07 e um sinal de clusters relativamente sobrepostos, o que faz sentido num dataset musical: as faixas podem partilhar intensidades semelhantes de energia, valência e dançabilidade, sem que isso se traduza em grupos radicalmente distintos. Em termos práticos, isto significa que o clustering é mais útil como ferramenta de segmentação e exploração do que como classificação rigorosa e definitiva.

Ao mesmo tempo, a forte accuracy do classificador auxiliar sugere que, apesar da sobreposição observada no silhouette, os clusters são suficientemente estruturados para serem reaprendidos por um modelo supervisionado. Esta combinação de sinais é interessante: os clusters não são perfeitamente separados no espaço geométrico, mas ainda assim mantêm uma identidade suficiente para uso operacional.

7.3 Leitura crítica da regressão

Na regressão, a interpretação deve ser feita com mais cautela porque o workflow não fecha ainda uma tabela consolidada de MAE, RMSE e R^2 para todos os modelos. O que o workflow mostra com segurança é que a preparação foi feita sem fuga de informação, a regressão linear e a árvore estão executadas e os resíduos foram diagnosticados visualmente.

Do ponto de vista metodológico, a regressão linear funciona como baseline interpretável. A árvore de regressão tem potencial para capturar não linearidades, mas a ausência de poda rigorosa pode aumentar a variância. O ramo de random forest, embora ainda não executado, é precisamente o tipo de modelo que pode oferecer um compromisso mais robusto entre viés e variância. Por isso, a comparação futura entre estes três modelos é o passo natural seguinte.

7.4 Limitações do estudo

A principal limitação é que o dataset é sintético, ainda que inspirado em distribuições realistas. Isso é útil para treino, mas não substitui completamente um catálogo real com variações de metadata mais complexas. Outra limitação é a ausência, no estado atual do workflow, de uma tabela única consolidada com métricas de regressão finalizadas. Por fim, o trabalho analisa associações e padrões, mas não pode afirmar causalidade entre as features e a popularidade.



Figure 16: Análise dos resíduos e limite dos modelos

8 Sugestões e recomendações

A primeira recomendação é completar a comparação de regressão com a execução do ramo de random forest e a consolidação das métricas finais numa tabela única. A segunda é testar diferentes números de clusters ou diferentes seeds para verificar estabilidade da segmentação. A terceira é aprofundar a interpretação dos clusters por gênero, por exemplo associando centroides a perfis musicais mais claros. A quarta é explorar importância das variáveis em regressão para identificar quais as features acústicas que mais contribuem para popularidade.

Do ponto de vista prático, o workflow poderia ainda ganhar robustez com validação cruzada em regressão, repetição de experiências com seeds diferentes e comparação entre escalas de normalização. Essas extensões não são necessárias para concluir o relatório, mas seriam um bom passo seguinte se o projeto continuasse.

9 Reprodutibilidade

Para reproduzir o trabalho, basta seguir a sequência geral do workflow. Primeiro, abrir o ficheiro do KNIME relativo ao dataset de grupo. Depois, executar o bloco de *data understanding* para confirmar leitura, distribuições e duplicados. Em seguida, correr o pipeline de preparação na ordem definida: remoção de duplicados, expression, missing value, numeric outliers e filtragem final. Depois, correr separadamente o ramo de clustering e o ramo de regressão, garantindo que a normalização e a partição são executadas antes dos modelos.

Os ficheiros que sustentam a reprodução são o CSV principal, o log de erros, o script de geração e o workflow KNIME. No caso de querer repetir a análise de raiz, convém confirmar se

os caminhos dos ficheiros estao corretos e se as ligacoes no KNIME apontam para a pasta do projeto.

10 Conclusao

O trabalho desenvolvido sobre o dataset de grupo mostra uma cadeia completa de analise de dados: exploracao, preparacao, modelacao e interpretacao. A maior forca do projeto esta na qualidade da preparacao e na coerencia entre o que foi visto nos dados e o que foi feito no workflow. No clustering, o resultado final e suficientemente rico para segmentacao e interpretacao musical. Na regressao, o pipeline esta bem montado e tem comparacao real entre abordagens, embora ainda beneficie de consolidacao de metricas.

Em suma, o relatorio documenta um processo analitico serio, reproduzivel e alinhado com CRISP-DM, com suficiente detalhe para justificar as escolhas feitas e com espaco claro para evolucao futura do modelo.