

Relatorio de Resultados

Dataset de Grupo: Spotify Tracks

Analise de Dados e Modelacao em KNIME

Unidade Curricular: Analise e Descoberta de Informacao

Grupo: [Preencher]

Elementos: [Preencher]

May 7, 2026

Contents

1 Introducao

Este relatorio documenta o trabalho realizado sobre o **dataset de grupo** do Spotify, com implementacao em *workflows* KNIME e enquadramento completo no metodo CRISP-DM. O objetivo foi descrever um processo analitico completo, focado em duas tarefas distintas e complementares: (i) **clustering** para descobrir perfis acusticos e (ii) **regressao supervisionada** para prever **popularity**. A avaliacao foi feita no mesmo dataset, com particao treino/teste e interpretacao adicional dos clusters por genero.

O texto foi escrito para refletir fielmente o que existe no workflow, evitando passos que nao foram implementados.

2 Dominio, objetivos e abordagem

2.1 Dominio analisado

O dominio escolhido e o da analise musical e de consumo digital. As caracteristicas acusticas podem apoiar segmentacao editorial, recomendacao e analise de perfis sonoros. Variaveis como *danceability*, *energy*, *loudness*, *acousticness* e *tempo* capturam propriedades musicais diretas, enquanto *genre*, *release_year* e *explicit* adicionam contexto de catalogo.

2.2 Objetivos

Os objetivos do trabalho sao:

- Garantir uma preparacao robusta dos dados (duplicados, missing, outliers e features derivadas);
- Descobrir perfis acusticos com *k-means* e interpretar a composicao dos clusters;
- Treinar modelos de regressao para prever **popularity** com base nas features acusticas;
- Produzir uma analise critica dos resultados, focada na interpretacao dos clusters e no desempenho de regressao.

2.3 Estrategia seguida

A estrategia foi iterativa e alinhada com CRISP-DM: leitura e exploracao dos dados, preparacao sequencial, modelacao em ramos separados e avaliacao com foco na regressao de **popularity**. Esta abordagem evita comparacoes indevidas entre tarefas diferentes (clustering vs regressao) e reforca a interpretacao baseada em dados.

3 Metodologia CRISP-DM

3.1 Compreensao do negocio

O objetivo analitico e caracterizar musica por perfis acusticos e prever **popularity**. A utilidade pratica inclui segmentacao de catalogo e leitura critica do que os atributos sonoros explicam sobre popularidade.

3.2 Compreensao dos dados

O workflow confirma a estrutura do CSV, identifica duplicados, missing e valores fora do dominio e valida a distribuicao dos generos. A exploracao inclui estatisticas descritivas, histogramas, boxplots e distribuicao por genero.

3.3 Preparacao dos dados

Foi implementado um pipeline sequencial: remocao de duplicados, saneamento de valores invalidos, imputacao de missing, tratamento de outliers e criacao de features derivadas. O objetivo e garantir consistencia das features e reduzir ruido antes da modelacao.

3.4 Modelacao

Foram criados dois ramos principais:

- **Clustering:** *k-means* com features acusticas normalizadas, avaliacao por elbow, silhouette e PCA.
- **Regressao supervisionada:** modelos linear e arvore de regressao para **popularity**, com normalizacao consistente e avaliacao com *Numeric Scorer*.

3.5 Avaliacao

Avaliacao quantitativa: metricas de regressao (R2, MAE e RMSE) no teste. Avaliacao qualitativa: interpretacao de clusters por genero real, evitando comparacao direta entre tarefas diferentes.

3.6 Deployment e uso

Os artefactos resultantes (modelo de clustering, modelos de regressao e tabelas de interpretacao) podem ser reutilizados para analise de novos datasets com a mesma estrutura, mantendo o mesmo pipeline de preparacao e normalizacao.

4 Descricao do dataset

4.1 Estrutura geral

O ficheiro `spotify_tracks.csv` contem **100 500 registos** e **21 colunas**. O periodo temporal vai de **2000 a 2024** e o dataset cobre **20 generos** musicais. O ficheiro `spotify_tracks_b.csv` tem a mesma estrutura e esta disponivel para teste externo, mas nao foi usado no workflow final. Existe ainda o ficheiro `spotify_tracks_errors_log.csv`, com o registo de erros introduzidos no gerador do dataset, usado para validar a preparacao de dados.

Table 1: Estrutura do dataset de grupo

Grupo de variaveis	Exemplos
Identificacao	<code>track_id</code> , <code>track_name</code> , <code>artist_name</code> , <code>album_name</code>
Contexto	<code>release_year</code> , <code>genre</code> , <code>explicit</code> , <code>key</code> , <code>mode</code> , <code>time_signature</code>
Target	<code>popularity</code>
Audio	<code>danceability</code> , <code>energy</code> , <code>loudness</code> , <code>speechiness</code> , <code>acousticness</code> , <code>instrumentalness</code> , <code>liveness</code> , <code>valence</code> , <code>tempo</code> , <code>duration_ms</code>

4.2 Qualidade dos dados

O dataset nao foi criado para ser limpo; foi criado para simular um ambiente realista de preparacao. O gerador introduz valores em falta, outliers, violacoes de dominio e duplicados. Isto significa que a analise nao podia comear diretamente pela modelacao. Era necessario demonstrar, com evidencia, que os problemas estavam identificados e que o workflow sabia resolvê-los de forma consistente.

Em termos praticos, os problemas mais relevantes sao os seguintes. Existem valores em falta nas features de audio, o que afeta tanto a analise exploratoria como a modelacao. Existem linhas duplicadas completas, que distorcem contagens, distribuicoes e treino de modelos. Existem ainda valores fora do dominio esperado em variaveis limitadas a intervalos bem definidos, como as features normalizadas entre 0 e 1, e outliers fortes em variaveis como `tempo`, `loudness` e `duration_ms`.

4.3 Exploracao inicial

A fase de exploracao foi organizada em torno de varios blocos visuais no KNIME. O objetivo era verificar rapidamente se o dataset estava lido corretamente, perceber a forma das distribuicoes e encontrar sinais de problemas a tratar.




Figure 1: Exploracao univariada do dataset Spotify



Figure 2: Outliers e dispersao inicial




Figure 3: Relacoes bivariadas entre features acusticas



Figure 4: Representatividade por genero

A exploracao mostrou que as variaveis acusticas tinham escalas muito diferentes, o que e natural, mas tambem confirmou que havia varios pontos de anomalia a tratar. Por exemplo, alguns valores de **danceability**, **valence** ou **energy** surgem fora do intervalo esperado. Em paralelo, o comportamento de **tempo** e **loudness** inclui valores extremos que justificam tratamento especifico. Esta leitura inicial explica porque o workflow nao passa diretamente da leitura do CSV para a modelacao.

5 Preparacao dos dados em KNIME

A preparacao foi desenhada como um pipeline sequencial, onde cada no acrescenta uma operacao concreta ao estado dos dados.

5.1 Remocao de duplicados

O primeiro passo foi o **Duplicate Row Filter**. A escolha de tratar duplicados antes de qualquer outra transformacao evita que a limpeza ou a imputacao sejam aplicadas duas vezes aos mesmos registos. O workflow compara praticamente todas as colunas relevantes e conserva a primeira ocorrencia, mantendo a ordem original. O resultado observado e claro: de 100 500 linhas iniciais, o dataset passa para 100 000 linhas, o que confirma a existencia de 500 duplicados removidos no inicio do pipeline.

5.2 Sanitizacao e engenharia de atributos

Depois dos duplicados, o `no Expression` concentra varias operacoes que poderiam estar espalhadas por mais nodos. Aqui sao feitas tres coisas muito importantes. Primeiro, valores invalidos em variaveis limitadas a dominos conhecidos sao convertidos em missing para serem resolvidos mais tarde com regra consistente. Segundo, a variavel `explicit` e transformada para uma representacao numerica binaria. Terceiro, sao criadas features derivadas como `duration_min` e a classe auxiliar `popularity_class`.

Esta etapa e crucial porque transforma o dataset num formato mais adequado a aprendizagem automatica sem perder a informacao original de contexto. A criacao de `duration_min` torna a duracao mais interpretavel do que `duration_ms`, e a variavel `popularity_class` permite estratificar o split de treino/teste e apoiar a leitura dos resultados.

5.3 Tratamento de valores em falta

O `no Missing Value` recebe tanto os missing originais do CSV como os que sao gerados pelo passo anterior. A estrategia nao e uniforme; e precisamente essa diferenca que mostra maturidade metodologica. Para algumas features, o workflow usa media; para outras, mediana; e para o target `popularity`, a linha e removida quando o valor esta em falta.

Table 2: Estrategias de imputacao no `no Missing Value`

Coluna	Estrategia
<code>danceability</code>	Mean
<code>valence</code>	Mean
<code>energy</code> , <code>speechiness</code> , <code>acousticness</code> , <code>instrumentalness</code> , <code>liveness</code> , <code>loudness</code> , <code>tempo</code> , <code>duration_ms</code>	Median
<code>popularity</code>	Remove Row

Depois desta fase, o dataset fica com 99 353 linhas. O valor e importante porque confirma que a preparacao nao removeu tudo indiscriminadamente; removeu apenas o que era metodologicamente necessario remover.

5.4 Tratamento de outliers

Os outliers continuos sao tratados num `no especifico`, `Numeric Outliers`, que opera sobre `duration_ms`, `loudness` e `tempo`. O criterio de deteccao e o IQR, com scalar 3.0, e a acao escolhida e substituir o valor fora de intervalo pelo limite admissivel mais proximo. Esta decisao e relevante porque preserva a linha e impede que observacoes extremas deformem a modelacao.

5.5 Selecao de variaveis e separacao de ramos

Depois da limpeza principal, o workflow organiza uma base comum com 15 colunas. A partir daqui o workflow divide-se em dois ramos:

- **Ramo de clustering:** usa 10 features acusticas, com normalizacao Min-Max para $[0,1]$.
- **Ramo de regressao:** mantem `popularity` como target, aplica normalizacao Min-Max e faz split treino/teste estratificado por `popularity_class`.




Figure 5: Pipeline de preparacao no KNIME

6 Modelacao

6.1 Clustering

O clustering procura agrupar faixas com perfis sonoros semelhantes. Para isso o workflow usa apenas as features acusticas normalizadas, o que e a opcao correta porque o objetivo nao e agrupar por ano, genero ou identificador, mas sim por assinatura sonora.

Metodo do cotovelo

A escolha do numero de clusters foi analisada com varias execucoes de k-Means para valores de k entre 3 e 9. O workflow nao usa uma funcao automatica pronta para o elbow; em vez disso, reconstrói manualmente a soma das distancias quadradas dentro de cada cluster e agrega os resultados num grafico de linha. Esse detalhe e importante porque mostra que a decisao de k nao foi arbitraria: foi suportada por uma curva de WCSS produzida no proprio KNIME.




Figure 6: Metodo do cotovelo

k-Means final

O modelo final de clustering foi fixado em **5 clusters**, com inicializacão aleatoria, seed 1 e maximo de 99 iteracoes. O output do proprio no inclui a coluna de cluster, pelo que não foi necessario um assigner separado. Esta decisao final é coerente com a leitura da curva do elbow e com a interpretacao posterior dos centroides.




Figure 7: Clusters projetados em duas dimensoes (PCA)




Figure 8: Centroides dos clusters por feature

Interpretacao dos clusters

Para tornar os clusters interpretaveis, o workflow devolve os centroides a forma longa, cria graficos de barras e junta o genero musical para verificar composicao de cada grupo. Esta parte é essencial porque um cluster sem leitura semantica tem pouco valor analitico.

A qualidade do agrupamento foi analisada adicionalmente com silhouette. O metodo hierarquico sobre uma amostra obteve um valor medio global de aproximadamente **0.0732**, o que é baixo e sugere sobreposicao entre grupos. Na comparacao entre $k = 4, 5$ e 6 , os valores globais observados foram aproximadamente **0.174**, **0.178** e **0.161**, respetivamente, o que suporta a escolha de $k = 5$ como compromisso.

► 1: Result table ► 2: Mean Silhouette Coefficient  Flow Variables

Rows: 5 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient  Number (Float)
☐	1	cluster_1	0.176
☐	2	cluster_2	0.138
☐	3	cluster_0	0.323
☐	4	cluster_3	0.165
☐	5	Overall	0.174

Figure 9: Silhouette para $k = 4$

► 1: Result table ► 2: Mean Silhouette Coefficient  Flow Variables

Rows: 6 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient  Number (Float)
☐	1	cluster_2	0.163
☐	2	cluster_3	0.145
☐	3	cluster_0	0.309
☐	4	cluster_1	0.248
☐	5	cluster_4	0.139
☐	6	Overall	0.178

Figure 10: Silhouette para $k = 5$

► 1: Result table ► 2: Mean Silhouette Coefficient  Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Mean Silhouette Coefficient .co Number (Float)
☐	1	cluster_1	0.243
☐	2	cluster_3	0.123
☐	3	cluster_5	0.121
☐	4	cluster_2	0.163
☐	5	cluster_0	0.141
☐	6	cluster_4	0.314
☐	7	Overall	0.161

Figure 11: Silhouette para $k = 6$



Figure 12: Distribuicao dos generos por cluster

Comparacao hierarquica

O workflow inclui ainda um ramo de clustering hierarquico com distancia euclidiana e linkage complete. Este ramo nao substitui o k-Means final, mas serve para comparar a qualidade da segmentacao. A leitura critica deste valor de silhouette e importante: o objetivo nao e apenas escolher um algoritmo, mas perceber se a estrutura dos dados suporta clusters nitidos ou se existe uma sobreposicao natural entre estilos musicais.

6.2 Regressao supervisionada de popularidade

O objetivo supervisionado e prever **popularity**. O workflow inclui um ramo de regressao linear e um ramo de arvore de regressao, ambos avaliados com *Numeric Scorer*. A normalizacao e feita no treino e aplicada ao teste para evitar fuga de informacao.




Figure 13: Ramo de regressao no KNIME




Figure 14: Regressao linear: real vs previsto




Figure 15: Regressao linear: distribuicao dos residuos

► 1: Statistics Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Prediction (popularity) Number (Float)
☐	1	R ²	0.018
☐	2	mean absolute error	13.307
☐	3	mean squared error	312.557
☐	4	root mean squared error	17.679
☐	5	mean signed difference	0.02
☐	6	mean absolute percentage error	NaN
☐	7	adjusted R ²	0.018

Figure 16: Metricas da regressao linear




Figure 17: Arvore de regressao: real vs previsto




Figure 18: Arvore de regressao: distribuicao dos residuos

► 1: Statistics Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Prediction (popularity) Number (Float)
☐	1	R ²	-1.092
☐	2	mean absolute error	18.846
☐	3	mean squared error	665.769
☐	4	root mean squared error	25.803
☐	5	mean signed difference	1.099
☐	6	mean absolute percentage error	NaN
☐	7	adjusted R ²	-1.092

Figure 19: Metricas da arvore de regressao




Figure 20: Random forest: real vs previsto




Figure 21: Random forest: distribuicao dos residuos

► 1: Statistics Flow Variables

Rows: 7 | Columns: 1

☐	#	RowID	Prediction (popularity) Number (Float)
☐	1	R ²	-0
☐	2	mean absolute error	13.615
☐	3	mean squared error	318.351
☐	4	root mean squared error	17.842
☐	5	mean signed difference	0.766
☐	6	mean absolute percentage error	NaN
☐	7	adjusted R ²	-0

Figure 22: Metricas da random forest

7 Resultados e analise critica

7.1 Resumo dos resultados mais relevantes

Table 3: Resumo dos principais resultados observados

Elemento	Resultado observado
Tamanho inicial do dataset	100 500 registos e 21 colunas
Duplicados removidos	500 linhas
Base comum apos preparacao	99 353 linhas e 15 colunas
Ramo de clustering	99 353 linhas e 10 features normalizadas
Split treino/teste	80/20, estratificado por <code>popularity_class</code> , seed 1
Silhouette hierarquico	aproximadamente 0.0732
Silhouettes adicionais ($k = 4, 5, 6$)	aproximadamente 0.174, 0.178 e 0.161
Cluster final	$k = 5$
Regressao linear	R ² de 0.018 e RMSE de 17.679
Arvore de regressao	R ² de -1.092 e RMSE de 25.803
Random forest	R ² de 0.0 e RMSE de 17.842

7.2 Leitura critica do clustering

Os resultados de clustering mostram que existe estrutura nos dados, mas a separacao nao e perfeita. Um silhouette perto de 0.07 e um sinal de clusters relativamente sobrepostos, o que faz sentido num dataset musical: as faixas podem partilhar intensidades semelhantes de energia, valencia e dancabilidade, sem que isso se traduza em grupos radicalmente distintos. Em termos praticos, isto significa que o clustering e mais util como ferramenta de segmentacao e exploracao do que como rotulagem rigorosa e definitiva.

Os clusters nao sao perfeitamente separados no espaco geometrico, mas ainda assim mantem uma identidade suficiente para uso operacional como segmentacao exploratoria.

7.3 Leitura critica da regressao de popularidade

Os resultados de regressao mostram capacidade limitada de explicacao da variabilidade de *popularity*. O R^2 baixo na regressao linear sugere que a relacao entre features acusticas e popularidade e fraca ou nao linear, enquanto a arvore de regressao apresenta desempenho inferior neste estado. Estes sinais sao consistentes com um target influenciado por fatores externos ao audio (marketing, contexto cultural e exposicao).

7.4 Limitações do estudo

A principal limitacao e que o dataset e sintético, ainda que inspirado em distribuicoes realistas. Isso e util para treino, mas nao substitui completamente um catalogo real com variacoes de metadata mais complexas. Outra limitacao e a ausencia, no estado atual do workflow, de uma tabela unica consolidada com metrias de regressao finalizadas. Por fim, o trabalho analisa associacoes e padroes, mas nao pode afirmar causalidade entre as features e a popularidade. Outra limitacao e a comparacao entre tarefas distintas: clustering e regressao respondem a perguntas diferentes. Por isso, a comparacao deve ser qualitativa (interpretacao dos clusters) e nao quantitativa por uma unica metrica.

8 Sugestoes e recomendacoes

Recomenda-se testar diferentes valores de k e seeds para avaliar estabilidade dos clusters e acrescentar uma analise de percentagens por cluster (normalizacao por cluster). No ramo de regressao, seria util consolidar as metricas numa tabela comparativa unica e testar tuning de hiperparametros para reduzir o erro. Estas extensoes nao sao obrigatorias para concluir o relatorio, mas ajudam a consolidar a interpretacao.

9 Reprodutibilidade

Para reproduzir o trabalho, basta seguir a sequencia geral do workflow. Primeiro, abrir o ficheiro do KNIME relativo ao dataset de grupo. Depois, executar o bloco de *data understanding* para confirmar leitura, distribuicoes e duplicados. Em seguida, correr o pipeline de preparacao na ordem definida: remocao de duplicados, expression, missing value, numeric outliers e filtragem final. Depois, correr separadamente o ramo de clustering e o ramo de regressao, garantindo que a normalizacao e a particao sao executadas antes dos modelos.

Os ficheiros que sustentam a reproducao sao o CSV principal, o log de erros, o script de geracao e o workflow KNIME. No caso de querer repetir a analise de raiz, convem confirmar se os caminhos dos ficheiros estao corretos e se as ligacoes no KNIME apontam para a pasta do projeto.

10 Conclusao

O trabalho desenvolvido sobre o dataset de grupo mostra um processo CRISP-DM completo: compreensao do problema, exploracao e preparacao, modelacao e avaliacao. O clustering permite segmentar perfis acusticos e a regressao supervisionada mede o quanto as features explicam **popularity**. A interpretacao por clusters complementa a avaliacao quantitativa e evita comparacoes indevidas entre tarefas diferentes. O resultado e um workflow coerente, reproduzivel e alinhado com boas praticas de analise de dados.