

Relatorio de Resultados

Analise de Dados e Modelacao em KNIME

(Duas Tarefas: Consumo Energetico e Spotify)

Unidade Curricular: Analise e Descoberta de Informacao

Grupo: [Preencher]

Elementos: [Preencher]

April 20, 2026

Contents

1	Introducao	4
2	Dominios, Objetivos e Estrategia	4
2.1	Dominios a tratar	4
2.2	Objetivos a alcancar	4
2.3	Como atingir os objetivos	4
3	Metodologia de Analise de Dados	5
4	Datasets e Exploracao Detalhada	5
4.1	Tarefa A - Dataset de consumo energetico	5
4.2	Tarefa B - Dataset Spotify (grupo)	7
5	Tratamento de Dados Efetuado em KNIME	8
5.1	Tarefa A - Pipeline de preparacao	8
5.2	Tarefa B - Pipeline de preparacao	9
6	Modelos Desenvolvidos e Configuracoes	10
6.1	Tarefa A - Classificacao de consumo	10
6.2	Tarefa B - Modelacao descritiva e preditiva	11
7	Sumario de Resultados e Analise Critica	13
7.1	Tabela-sintese de resultados (preencher com valores KNIME)	13
7.2	Analise critica	13
7.3	Leitura dos resultados por tarefa	13
7.4	Limitacoes e ameacas a validade	14
8	Sugestoes e Recomendacoes	15
8.1	Recomendacoes tecnicas	15
8.2	Recomendacoes de negocio/aplicacao	15
9	Reprodutibilidade	15
9.1	Estrutura de ficheiros utilizada	15
9.2	Passos para reproducao	16
9.3	Elementos a anexar para submissao	16
10	Conclusao	16

1 Introducao

Este relatorio apresenta, de forma integrada, o trabalho desenvolvido para duas tarefas de analise de dados, com implementacao em *workflows* KNIME:

- **Tarefa A (atribuida):** classificacao de classes de consumo energetico com base em variaveis eletricas, meteorologicas e temporais;
- **Tarefa B (grupo):** exploracao, tratamento e modelacao de um dataset de faixas Spotify, com componentes de *clustering*, analise exploratoria e regressao de popularidade.

O relatorio aborda os dominios, os objetivos, a metodologia, a exploracao detalhada de ambos os datasets, o tratamento de dados, os modelos desenvolvidos, os resultados obtidos, analise critica e recomendacoes. Os passos sao descritos de modo a permitir reproducao dos procedimentos.

2 Dominios, Objetivos e Estrategia

2.1 Dominios a tratar

- **Energia e meteorologia:** padroes de consumo eletrico em funcao de condicoes atmosfericas e caracteristicas temporais.
- **Musica digital e comportamento de audicao:** relacao entre atributos acusticos e popularidade; segmentacao de faixas por perfil sonoro.

2.2 Objetivos a alcancar

1. Construir pipelines robustos de preparacao de dados para cenarios com erros reais (valores em falta, outliers, ruido e duplicados).
2. Desenvolver modelos preditivos e descritivos adequados ao problema (classificacao, regressao e clustering).
3. Comparar alternativas de modelacao e interpretar resultados de forma critica.
4. Produzir conclusoes e recomendacoes com utilidade pratica.

2.3 Como atingir os objetivos

A estrategia foi organizada em fases:

1. caracterizacao dos dados e auditoria inicial de qualidade;
2. limpeza e transformacao orientadas ao problema;
3. analise exploratoria para suporte de decisoes de modelacao;
4. treino, validacao e comparacao de modelos;
5. interpretacao de resultados e formulacao de recomendacoes.

3 Metodologia de Analise de Dados

Neste trabalho foi aplicado o metodo **CRISP-DM** (Cross-Industry Standard Process for Data Mining), adaptado ao contexto de dois problemas distintos e implementado em KNIME. Em vez de uma execucao linear, a aplicacao foi iterativa: os resultados de cada fase alimentaram ajustes nas fases anteriores, sobretudo na preparacao de dados e na modelacao.

Na fase de **compreensao do negocio/problema**, definimos para cada tarefa a pergunta analitica principal, o tipo de output esperado e o criterio de sucesso. Na Tarefa A, o objetivo era classificar corretamente os niveis de consumo energetico (**Consumptions**) para apoiar leitura operacional da procura. Na Tarefa B, o objetivo foi duplo: obter segmentacoes coerentes de perfis sonoros e construir modelos de regressao para estimar **popularity**.

Na **compreensao dos dados**, realizamos auditoria inicial com estatisticas descritivas, distribuicoes, contagens por categoria, boxplots e correlacoes. Esta etapa permitiu identificar variaveis com escalas muito diferentes, potenciais outliers, padroes sazonais e problemas de qualidade de dados. No dataset Spotify, esta fase foi particularmente importante por existirem erros injetados (faltas, duplicados e anomalias numericas) documentados no respetivo log.

A fase de **preparacao dos dados** foi a mais extensa, incluindo limpeza, transformacao e engenharia de atributos. Aplicamos tratamento de valores em falta com estrategias diferenciadas (media, mediana ou remocao de linha, conforme a coluna), tratamento de outliers com criterio IQR, filtragem de duplicados, normalizacao Min-Max e criacao de variaveis derivadas temporais e de interacao. O principio orientador foi preservar informacao relevante e, ao mesmo tempo, reduzir ruido que pudesse degradar o desempenho dos modelos.

Na fase de **modelacao**, foram treinados e comparados modelos adequados a cada problema: classificadores (Decision Tree, Random Forest, Gradient Boosted Trees, MLP) na Tarefa A; e combinacao de clustering e regressao na Tarefa B. Sempre que aplicavel, mantivemos sementes fixas para reprodutibilidade e procedemos a particao treino/teste com criterio estratificado para reduzir enviesamentos na avaliacao.

Na **avaliacao**, utilizamos metricas alinhadas com o tipo de tarefa e analisamos nao apenas os valores agregados, mas tambem o comportamento do erro. Em classificacao, para alem de accuracy, consideramos o equilibrio entre classes atraves de precision/recall/F1. Em regressao, priorizamos MAE e RMSE quando o MAPE se mostrava instavel para valores reais proximos de zero. Esta leitura permitiu comparar modelos com maior rigor e identificar limitacoes praticas.

Por fim, a fase de **comunicacao e deploy analitico** foi concretizada neste relatorio, com foco em reproducao, interpretacao e recomendacoes acionaveis. Embora nao tenha sido implementado deploy em producao, foram identificados passos de operacionalizacao, incluindo monitorizacao de desempenho, politica de re-treino e atualizacao de pipelines no KNIME.

4 Datasets e Exploracao Detalhada

4.1 Tarefa A - Dataset de consumo energetico

Origem e estrutura

O dataset de consumo energetico (ficheiro `consumption_dataset.csv`) contem **8 736 registos uteis** (8 737 linhas incluindo cabecalho) e integra:

- variaveis de consumo por nivel de tensao (Very High, High, Medium, Low e Total);

- variaveis meteorologicas (temperatura, humidade, precipitacao, radiacao, vento, etc.);
- timestamp (Date/Time);
- classe-alvo **Consumptions** (classe de consumo).

A descricao semantica dos atributos foi confirmada no ficheiro `consumption_explanation.txt`.

Exploracao inicial

A exploracao incluiu estatisticas descritivas, boxplots e correlacao linear para identificar:

- escalas muito diferentes entre variaveis;
- relacoes relevantes entre variaveis meteorologicas e carga/consumo;
- presenca de valores em falta em alguns campos.



Figure 1: Distribuicao da variavel-alvo na Tarefa A




Figure 2: Correlacao entre atributos na Tarefa A



Figure 3: Dispersao e outliers na Tarefa A

4.2 Tarefa B - Dataset Spotify (grupo)

Origem e estrutura

O dataset `spotify_tracks.csv` contem **100 500 registros** (100 501 linhas incluindo cabeçalho), com atributos de identificacao musical e *features* de audio, incluindo:

- metadados: `track_id`, `track_name`, `artist_name`, `album_name`, `release_year`, `genre`;
- alvo/indicador de interesse: `popularity`;
- atributos acusticos: `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, etc.

A geracao dos dados foi efetuada por `create_dataset.py`, com injecao intencional de problemas de qualidade:

- valores em falta (3% por coluna de audio);
- outliers numericos (0.7% em colunas selecionadas);
- erros de formato/tipo (strings em colunas numericas, conforme documentacao do gerador);
- duplicados (500 linhas adicionadas).

O ficheiro `spotify_tracks_errors_log.csv` regista o *ground truth* dos erros injetados e possui 31 000 entradas de erro (31 001 linhas com cabeçalho).

Exploracao inicial

A exploracao incluiu distribuicoes, contagens por genero, analise de outliers e correlacoes, com foco nas *features* acusticas e popularidade.

[INSERIR IMAGEM KNIME]

Figure 4: Exploracao univariada do dataset Spotify

[INSERIR IMAGEM KNIME]

Figure 5: Representatividade por genero musical

[INSERIR IMAGEM KNIME]

Figure 6: Relacoes entre variaveis no dataset Spotify

5 Tratamento de Dados Efetuado em KNIME

5.1 Tarefa A - Pipeline de preparacao

No workflow `atribuido.knwf`, foram identificados blocos de preparacao e enriquecimento de dados:

- **Conversao temporal:** `String to Date_Time` e `Date_Time Part Extractor` para derivar atributos de calendario (mes, dia da semana, hora);
- **Tratamento de faltas:** `Missing Value`;
- **Selecao/filtragem de atributos:** `Column Filter`, `Row Filter`;
- **Agregacao e engenharia:** `GroupBy`, `Java Snippet` (ex.: interacoes como `temperatureXhour`, variaveis indicadoras como `is_weekend` e `is_peak_hour`);
- **Apoio exploratorio:** `Statistics`, `Linear Correlation`, `Box Plot`, `Numeric Outliers`.

5.2 Tarefa B - Pipeline de preparacao

No workflow `dataset_grupo.knwf`, o tratamento foi explicito e orientado a qualidade:

- **Detecao/remocao de duplicados:** `Duplicate Row Filter` com chave composta por 20 colunas (exclui `track_id`); opcao `remove_duplicates=true`;
- **Tratamento de faltas:** `Missing Value` com estrategia por atributo:
 - media em `danceability` e `valence`;
 - mediana em `energy`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `loudness`, `tempo`, `duration_ms`;
 - remocao de linha quando `popularity` falta.
- **Outliers:** `Numeric Outliers` em `duration_ms`, `loudness`, `tempo` com `IQR scalar = 3.0` e substituicao por *closest permitted value*;
- **Transformacao/normalizacao:** `Normalizer Min-Max` para intervalo $[0,1]$ nas variaveis numericas de modelacao;
- **Particao treino/teste:** `Table Partitioner` com 80% treino / 20% teste, estratificado por `popularity_class`, `seed=1`.



Figure 7: Pipeline de tratamento de dados - Tarefa A



Figure 8: Pipeline de tratamento de dados - Tarefa B

6 Modelos Desenvolvidos e Configuracoes

6.1 Tarefa A - Classificacao de consumo

Foram utilizados quatro modelos principais no workflow atribuido:

Decision Tree

- Alvo: `Consumptions`
- Criterio de divisao: Gini index
- Minimo por no: 2 registros
- Pruning: No pruning
- Estrategia para missings: `lastPrediction`

Random Forest (classificacao)

- Alvo: Consumptions
- Numero de modelos (arvores): 496
- *Split criterion*: Information Gain Ratio
- *Column sampling*: SquareRoot
- *Row sampling*: Random, fracao 1.0, sem reposicao
- *Seed*: 1764585560353

Gradient Boosted Trees (classificacao)

- Alvo: Consumptions
- Numero de modelos: 300
- Profundidade maxima: 4
- *Learning rate*: 0.1
- *Split criterion*: Information Gain Ratio

Rede Neural (RProp MLP)

- Alvo: Consumptions
- 1 camada escondida
- 27 neuronios na camada escondida
- Maximo de iteracoes: 300
- *Seed*: -918993344

A avaliacao foi suportada por Scorer e validacao cruzada com X_Partitioner/X_Aggregator.

6.2 Tarefa B - Modelacao descritiva e preditiva

k-Means (segmentacao)

- Atributos usados: danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo, duration_min
- Numero de clusters: 3 (em configuracao base observada)
- Inicializacao: aleatoria
- Iteracoes maximas: 99
- *Seed*: 1

Clustering hierarquico + Silhouette

O workflow inclui `Hierarchical Clustering` e `Silhouette Coefficient`, permitindo comparar qualidade de agrupamentos e suportar a escolha de k em análise complementar.

PCA (análise e visualização)

Foi incluída redução dimensional com `PCA Compute` + `PCA Apply`, com suporte visual via `Scatter Plot` e coloração por cluster.

Regressão de popularidade

Foram observados pelo menos dois modelos:

- **Linear Regression Learner**
 - alvo: `popularity`
 - constante incluída
 - tratamento de missing no treino: `fail`
- **Simple Regression Tree Learner**
 - modelo não linear para capturar relações com limiares.

A avaliação de regressão foi feita com `Numeric Scorer`, comparando `popularity` com `Prediction (popularity)`. O node registou aviso sobre MAPE para linhas com valor real 0.



Figure 9: Segmentação de faixas no dataset Spotify

[INSERIR IMAGEM KNIME]

Figure 10: Comparacao de modelos por metrica

7 Sumario de Resultados e Analise Critica

7.1 Tabela-sintese de resultados (preencher com valores KNIME)

Table 1: Resumo de desempenho - Tarefa A (classificacao)

Modelo	Accuracy	Precision (macro)	Recall (macro)	F1 (macro)
Decision Tree	[preencher]	[preencher]	[preencher]	[preencher]
Random Forest	[preencher]	[preencher]	[preencher]	[preencher]
Gradient Boosted Trees	[preencher]	[preencher]	[preencher]	[preencher]
RProp MLP	[preencher]	[preencher]	[preencher]	[preencher]

Table 2: Resumo de desempenho - Tarefa B (regressao)

Modelo	MAE	RMSE	R^2	MAPE
Linear Regression	[preencher]	[preencher]	[preencher]	[preencher/NA]
Regression Tree	[preencher]	[preencher]	[preencher]	[preencher/NA]

7.2 Analise critica

- Na Tarefa A, modelos de *ensemble* tendem a superar arvores simples por capturarem melhor nao linearidades e interacoes entre variaveis meteorologicas e temporais.
- O desempenho de redes neurais depende fortemente de normalizacao e parametrizacao (neurons, iteracoes, seed), podendo variar entre execucoes.
- Na Tarefa B, a qualidade da preparacao foi determinante, dado o dataset conter erros injetados de forma sistematica.
- O aviso de MAPE no `Numeric Scorer` evidencia limitacao da metrica quando existem valores reais zero; nestes casos, MAE/RMSE devem ter prioridade interpretativa.

- O clustering fornece valor exploratorio (tipologias sonoras), mas requer validacao com metrica interna (silhouette) e leitura de negocio para ser acionavel.

7.3 Leitura dos resultados por tarefa

Tarefa A - Classificacao

Para a Tarefa A, a comparacao entre modelos deve privilegiar a combinacao de **F1 macro** e matriz de confusao, porque a classe **Consumptions** pode apresentar distribuicao desigual entre niveis. Mesmo quando a *accuracy* global e elevada, importa verificar se classes menos frequentes estao a ser corretamente identificadas. Este ponto e critico em contexto energetico, onde erros em periodos de pico podem ter maior impacto operacional do que erros em periodos de consumo medio.

Outro aspeto relevante e a estabilidade do modelo ao longo do tempo. Como existem variaveis meteorologicas e temporais, recomenda-se validar a consistencia por janelas temporais (ex.: semanas/meses) para detetar degradacao de desempenho sazonal. Essa analise ajuda a decidir quando re-treinar o modelo e que variaveis devem ser monitorizadas em producao.

Tarefa B - Clustering e Regressao

No clustering, a avaliacao nao deve ficar limitada a metrica interna; e necessario interpretar os centroides para traduzir cada cluster em perfis musicais compreensiveis (por exemplo: mais energetico e dançavel vs. mais acustico e instrumental). Esta leitura semantica transforma um resultado tecnico numa segmentacao acionavel para recomendacao, curadoria e campanhas editoriais.

Na regressao de **popularity**, as metricas MAE e RMSE devem ser priorizadas sempre que o MAPE apresenta comportamento instavel em torno de valores reais nulos. Alem disso, a diferenca entre treino e teste deve ser observada para identificar sinais de sobreajuste. Se a arvore de regressao superar a regressao linear de forma consistente, isso sugere relacoes nao lineares entre as *features* acusticas e a popularidade.


7.4 Limitacoes e ameacas a validade

- O dataset Spotify e sintetico e inclui erros injetados de forma controlada; logo, os resultados podem nao refletir integralmente a complexidade de catalogos reais.
- Parte da interpretacao depende da qualidade da variavel **Consumptions** e da forma como as classes foram originalmente definidas.
- As conclusoes sobre causalidade sao limitadas: os modelos capturam associacoes estatisticas, nao relacoes causais garantidas.
- Configuracoes com *seed* fixa aumentam reprodutibilidade, mas convem repetir experiencias com seeds alternativas para medir robustez.



[INSERIR IMAGEM KNIME]

Figure 11: Matriz de confusao - classificacao de consumo



[INSERIR IMAGEM KNIME]

Figure 12: Analise de erro dos modelos de regressao

8 Sugestoes e Recomendacoes

8.1 Recomendacoes tecnicas

1. **Aprofundar validacao:** usar validacao cruzada estratificada tambem na Tarefa B para reduzir variancia de avaliacao.
2. **Ajuste de hiperparametros:** aplicar pesquisa sistematica (*grid/random search*) para ensemble e MLP.
3. **Engenharia de atributos:** explorar interacoes adicionais (ex.: sazonalidade detalhada, transformacoes ciclicas de hora/mes, combinacoes acusticas).
4. **Robustez estatistica:** testar imputacao robusta por genero/periodo e metodos alternativos de tratamento de outliers.
5. **Interpretabilidade:** adicionar analise de importancia de atributos e perfis de cluster para suporte a decisao.

8.2 Recomendacoes de negocio/aplicacao

- **Energia:** usar previsoes por classe para planejamento de carga, deteccao antecipada de periodos criticos e apoio a medidas de eficiencia.
- **Spotify:** utilizar clusters para curadoria de playlists, segmentacao editorial e testes de estrategia de lancamento.

9 Reprodutibilidade

9.1 Estrutura de ficheiros utilizada

- `atribuido.knwf` – workflow da Tarefa A.
- `dataset_grupo.knwf` – workflow da Tarefa B.
- `dataset/atribuido/consumption_dataset.csv` – dados da Tarefa A.
- `dataset/atribuido/consumption_explanation.txt` – dicionario de atributos da Tarefa A.
- `dataset/grupo/spotify_tracks.csv` – dados da Tarefa B.
- `dataset/grupo/spotify_tracks_errors_log.csv` – log de erros injetados.
- `dataset/grupo/create_dataset.py` – script de geracao dos dados Spotify.

9.2 Passos para reproducao

1. Abrir o KNIME Analytics Platform.
2. Importar os workflows `atribuido.knwf` e `dataset_grupo.knwf`.
3. Garantir que os caminhos para os CSVs estao corretos no(s) `CSV Reader`.
4. Executar os workflows por blocos: exploracao, preparacao, modelacao e avaliacao.
5. Exportar tabelas de metricas e imagens dos graficos para inserir neste relatorio.

9.3 Elementos a anexar para submissao

- Relatorio PDF final (maximo 30 paginas);
- Capturas dos graficos e tabelas de desempenho finais;
- Workflows KNIME e datasets utilizados.

10 Conclusao

O trabalho desenvolvido demonstra um ciclo completo de analise de dados em dois dominios distintos, com enfase em qualidade de dados, modelacao e interpretacao. A combinacao de procedimentos exploratorios, tratamento sistematico e comparacao de modelos permitiu produzir resultados reproduziveis e orientados a decisao. As recomendacoes apresentadas visam reforcar robustez, desempenho e aplicabilidade dos modelos em contexto real.